Iniciación práctica al análisis de datos OMOP

Mapeo de datos al OMOP CDM y controles de calidad: el ejemplo de SIDIAP

Elena Roel Herranz
eroel@idiapjgol.org

Sergio Fernández Bertolín
sfernandez@idiapjgol.org

SIDIAP

- Sistema de Información para el Desarrollo de la Investigación en Atención Primaria (SIDIAP)

- Base de datos de historias clínicas electrónicas de atención primaria de que incluye al 75% de la población desde el 2006 (6.1 M personas activas en 2024)

- Los datos son recogidos por >30.000 profesionales de 328 centros de atención primaria del *Institut Català de la Salut* (principal proveedor en Cataluña)

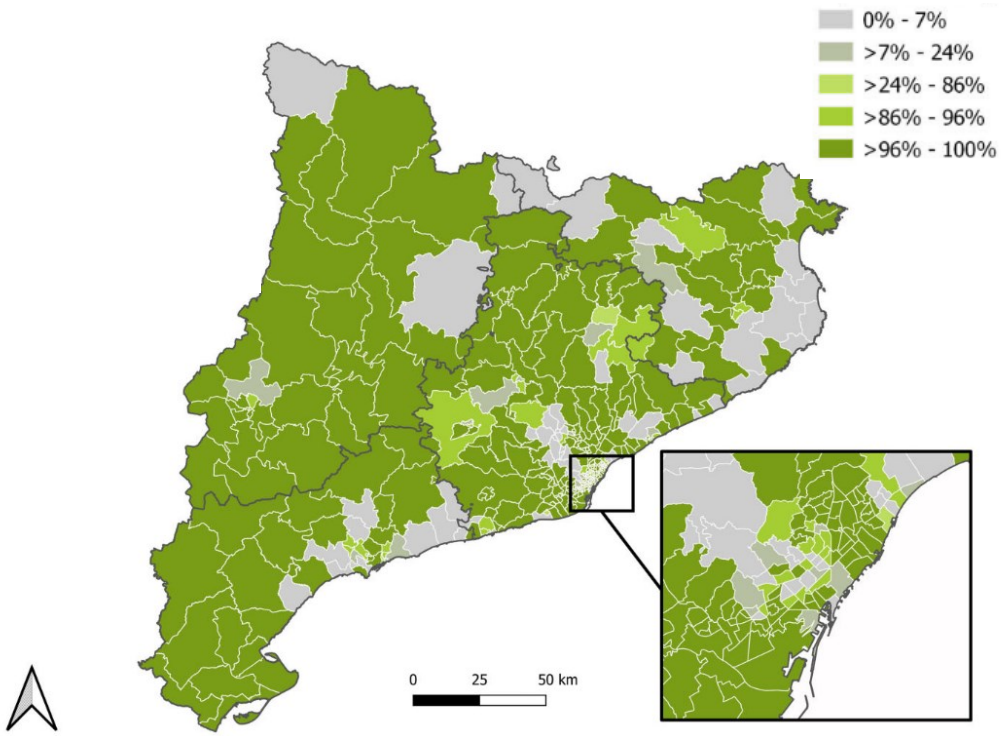

Fig. Cobertura del SIDIAP, 30 de Junio 2021

Source: Recalde et al (2022)

La información clínica se recoge en eCAP

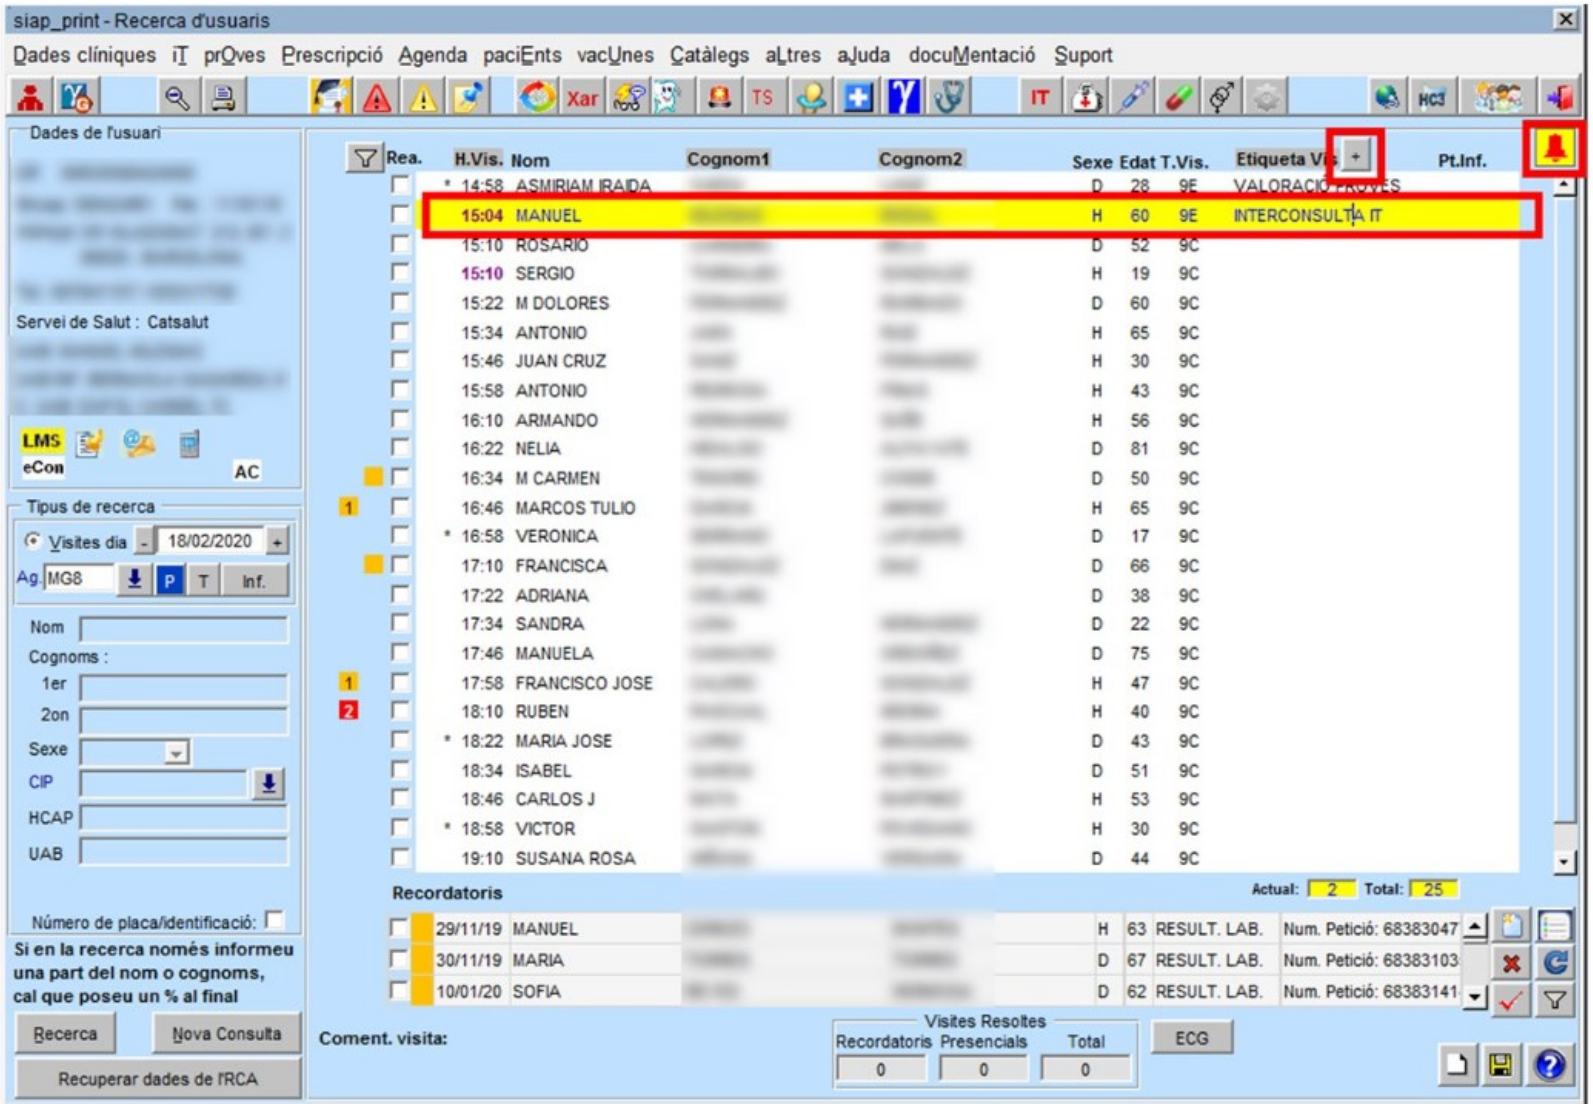

SIDIAP es representativo de la población de Cataluña

Fig. Age and sex distribution in SIDIAP and in the general population of Catalonia ,30 June 2021

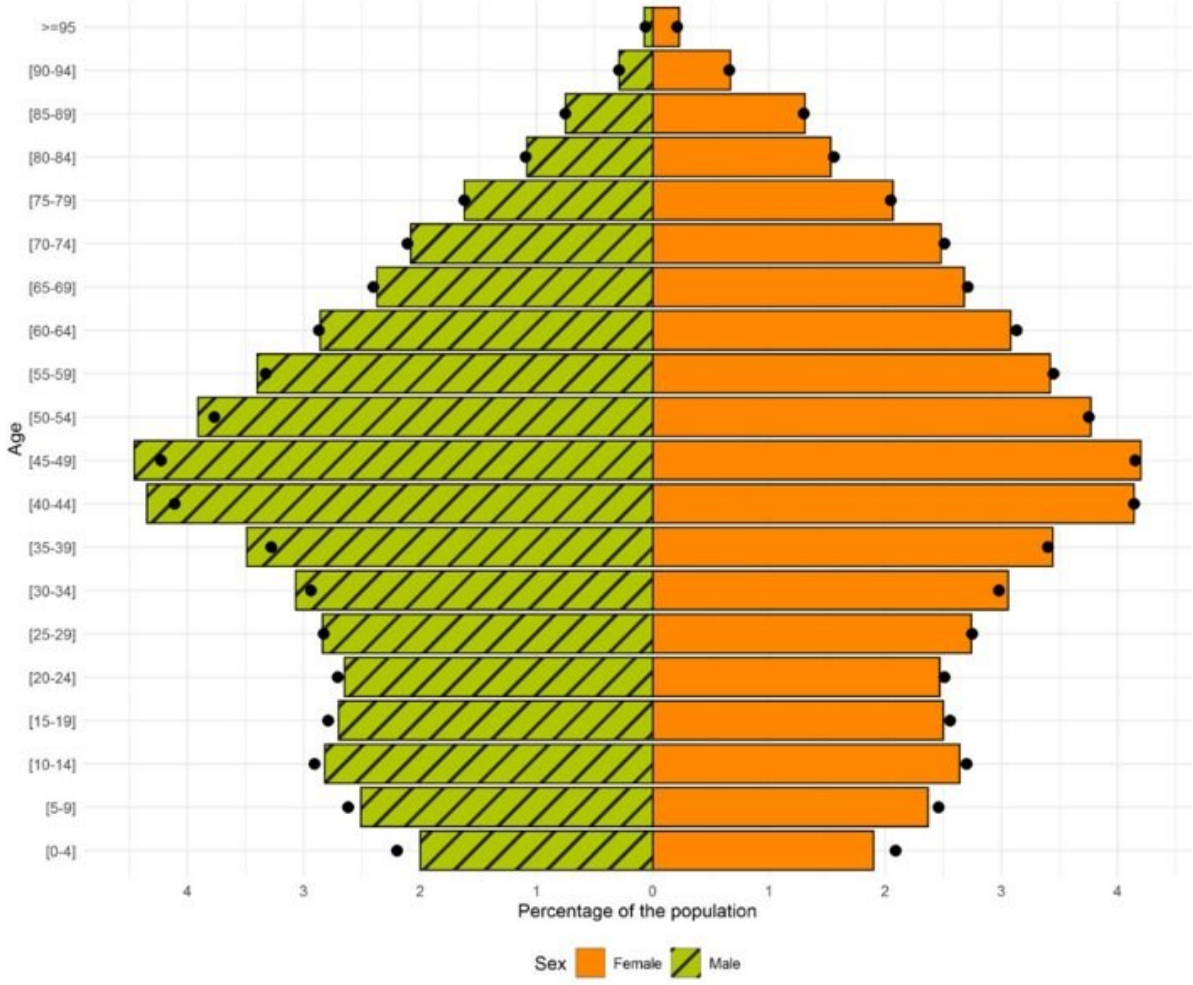

Datos disponibles

- Var. demográficas: edad, sexo, nacionalidad, nivel socioeconómico
- Estilos de vida: tabaco, alcohol, lactancia materna
- Medidas: IMC, presión arterial…
- Diagnósticos (códigos CIE10)
- Fármacos: prescripciones y dispensaciones
- Resultados de laboratorio: Hb, LDL…
- Bajas laborales
- Mortalidad (sin causa)
- Embarazos
- Vinculación madre-hijx

Fig. % de la pob. De SIDIAP con al menos un registro de variables clave, por año

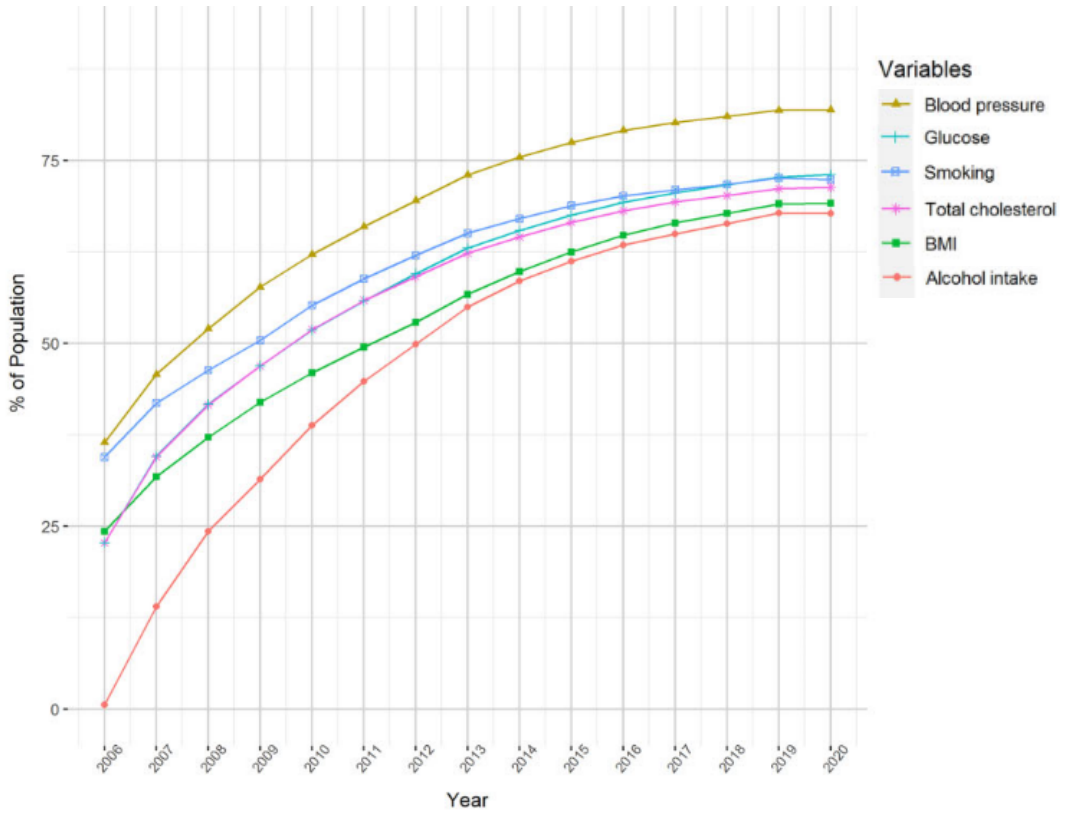

Datos disponibles

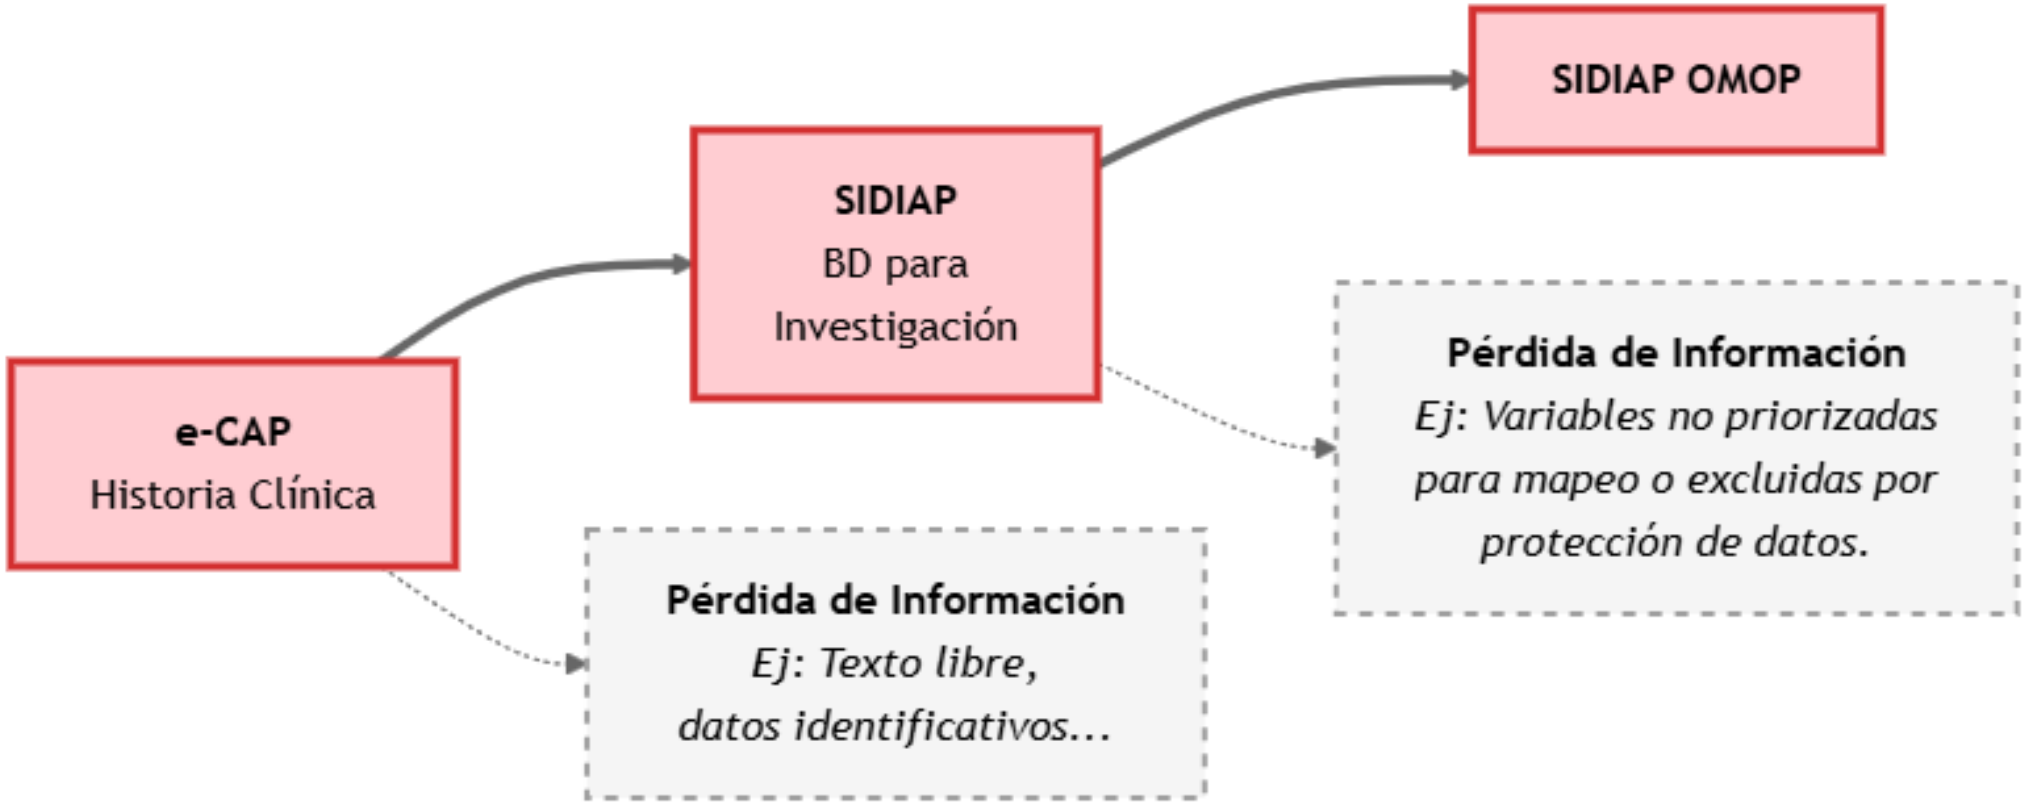

Vinculación a otras fuentes de datos

- Registros de cáncer
- Variables ambientales
- Causas de mortalidad (INE)
- Medicación Hospitalaria de Dispensación Ambulatoria (MHDA) [establecido]
- a
- Conjunto mínimo básico de datos (CMBD) de todos los hospitals [establecido]

Vinculación a otras fuentes de datos

- Registros de cáncer
- Variables ambientales
- Causas de mortalidad (INE)
- Medicación Hospitalaria de Dispensación Ambulatoria (MHDA) [establecido]
- a
- Conjunto mínimo básico de datos (CMBD) de todos los hospitals [establecido]

CMBD

Identificadores de paciente

- CIP Paciente
- Código del hospital, región
- Sexo, fecha de nacimiento

Identificadores del proceso

- Fecha de ingreso
- Fecha de alta
- Fecha de intervención

Variables clínicas

- Diagnóstico principal
- Otros diagnósticos
- Procedimientos

Calidad de los datos

Procesos internos

- Homogeneización de unidades
- Plausibilidad de los datos (valores inusuales…)
- Control de Calidad de cada proyecto

Procesos externos (estudios de validación)

- Análisis de texto libre
- Cuestionarios a profesionales
- Vinculación a fuentes de datos externas *gold standard* (ej, registros de cáncer)

Limitaciones

- Datos *missing* o desactualizados
- Infrarregistro, errores
- Información importante solo en texto libre
- Poca información sobre estilos de vida
- Cambios en el tiempo en la manera de registrar
- Más información sobre personas más “enfermas” (sesgo de observación)
- Falta de información sobre atención especializada, serv. privados

Fortalezas

- Representatividad
- Tamaño muestral
- Vinculación a otras fuentes
- Incluye variables poco frec. en otros RWD
- Desde 2006, actualizaciones anuales
- Estandarizado a OMOP CDM

Fortalezas

- Representatividad
- Tamaño muestral
- Vinculación a otras fuentes
- Incluye variables poco frec. en otros RWD
- Desde 2006, actualizaciones anuales
- Estandarizado a OMOP CDM

Embarazos, Vinculación madre-hijx, Mortalidad, Variables ambientales, Nivel de ingresos, …

Ventajas de OMOP

- Controles de calidad adicionales
- Acceso a los datos más fácil, preservando la confidencialidad
- Más flexibilidad para el equipo investigador
- Uso de herramientas OMOP para el análisis
- Facilita la realización de estudios en red
- Comparabilidad con otras BD / replicabilidad

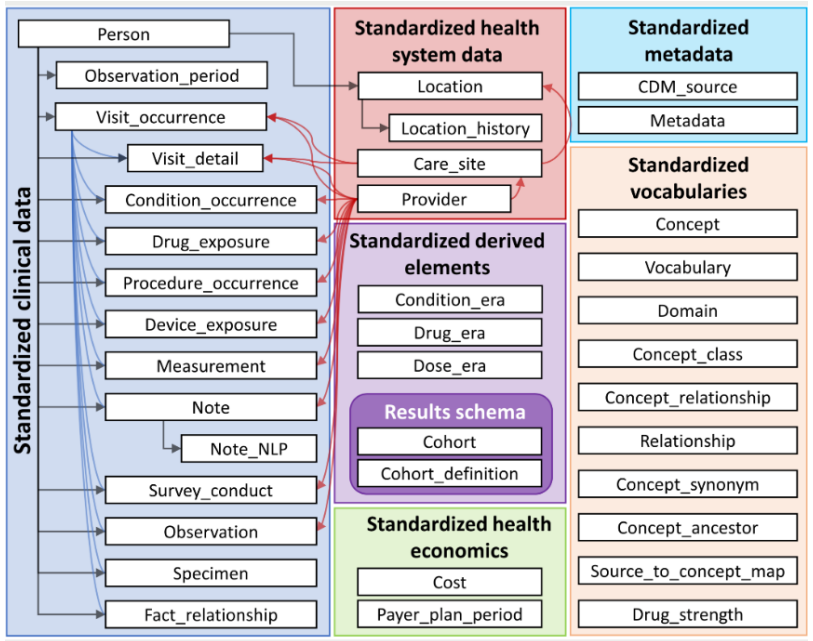

De SIDIAP a OMOP: ¿Por dónde empiezo?

Análisis de datos

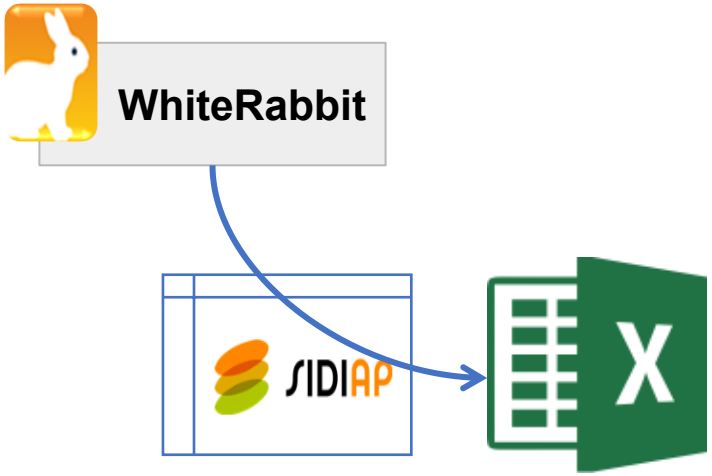

Tabla población

Table	Field	Type	Max length	N rows	Fraction empty	N unique values	Fraction unique
poblacio	id_cip	int	8	8663728	0,0%	100000	100,0%
poblacio	up	varchar	5	8663728	0,0%	341	0,3%
poblacio	sit	varchar	1	8663728	0,0%	3	0,0%
poblacio	entra	date	10	8663728	0,0%	5669	5,7%
poblacio	surt	date	10	8663728	0,0%	5376	5,4%
poblacio	sex	varchar	1	8663728	0,0%	2	0,0%
poblacio	naix	date	10	8663728	0,0%	34407	34,4%
poblacio	edat	int	3	8663728	0,0%	116	0,1%
poblacio	desc_agr_pais	varchar	24	8663728	21,9%	22	0,0%

De SIDIAP a OMOP: ¿Por dónde empiezo?

Análisis de datos

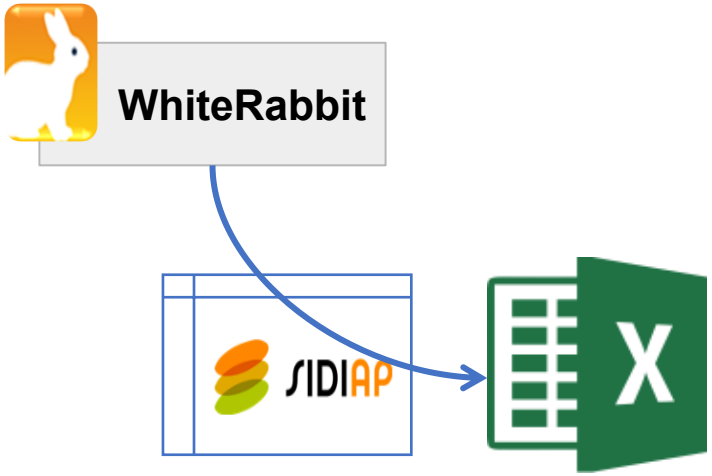

Resumen de tablas

Table	N rows	N Fields	N Fields Empty
derivacions	31982861	5	0
charlson	14853963	4	0
proves	32524714	8	0
variables	1646916368	5	0
prescripcio	452604015	14	0

Valores y su frecuencia en cada tabla

De SIDIAP a OMOP: La lógica del mapeo

Análisis de datos → Definir lógica → ETL

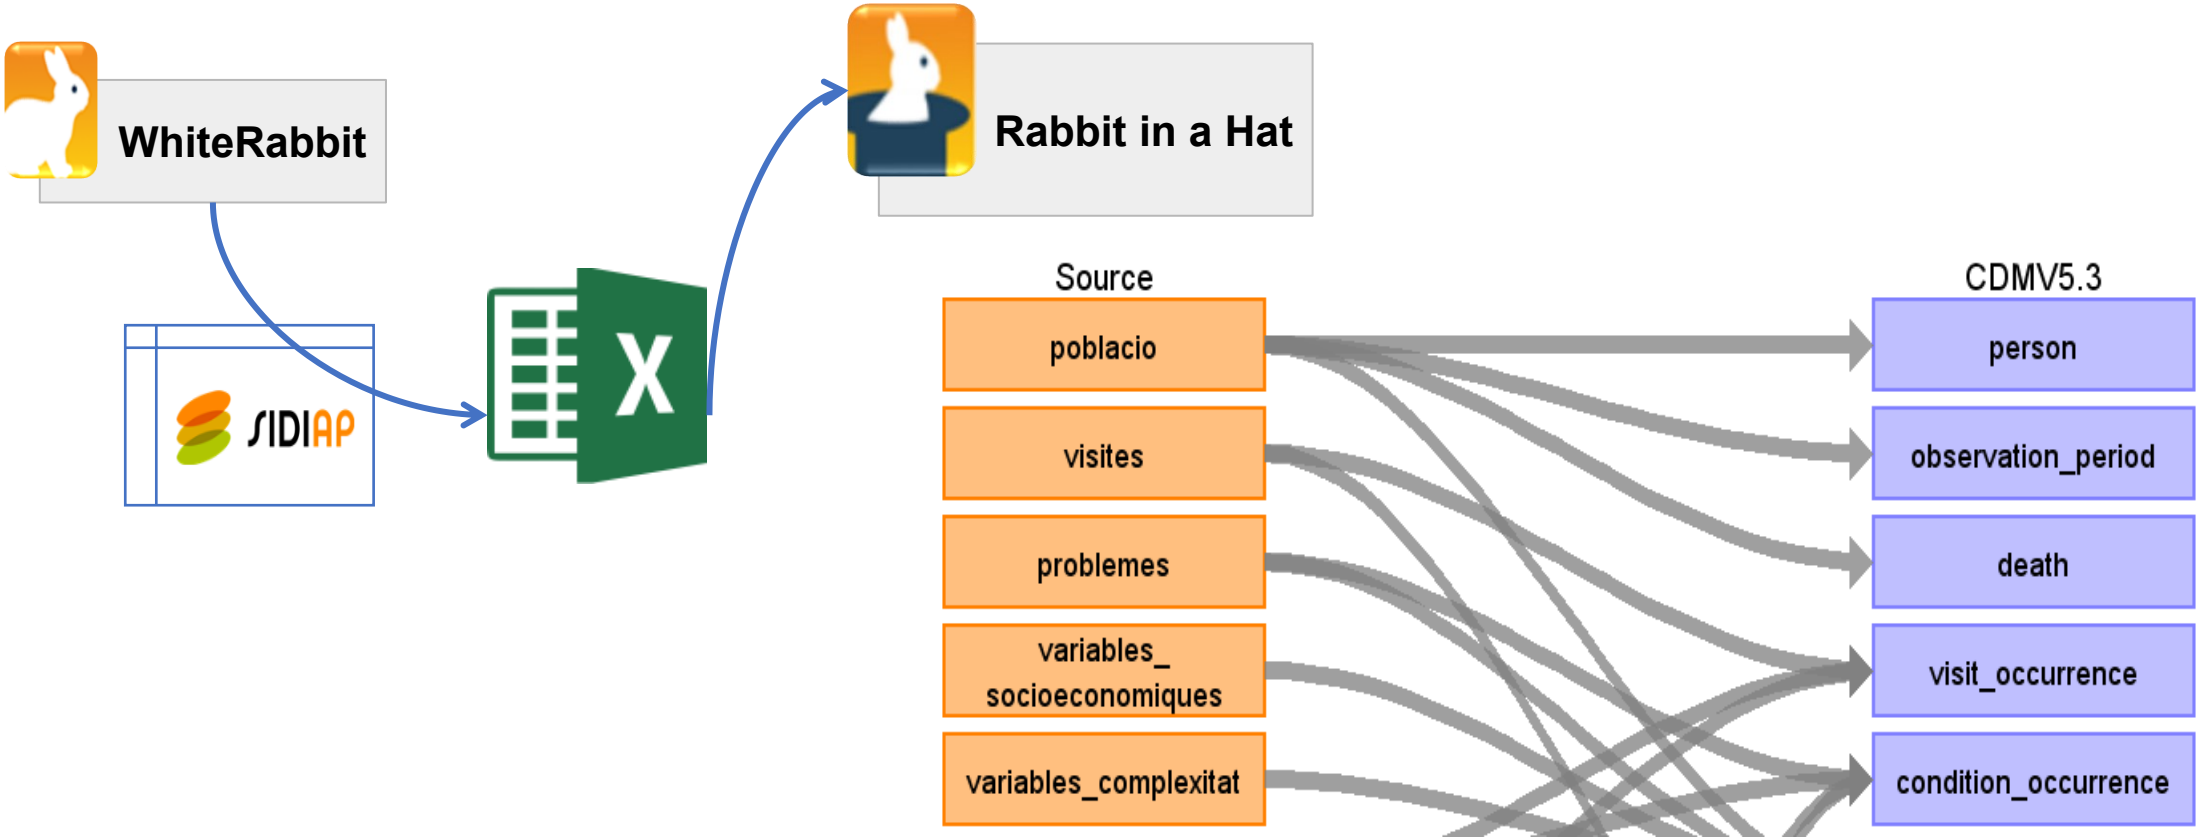

De SIDIAP a OMOP: Tablas

Tabla SIDIAP	Tabla OMOP
població	person death observation_period
visites	visit_occurrence
problemes	condition_occurrence observation
farmacs_prescrits	drug_exposure
farmacs_facturats	drug_exposure
vacunes	drug_exposure
variables_analitiques	measurement
variables_cliniques	measurement observation

De SIDIAP a OMOP: Códigos

Tipos de conversión

- **Por vocabulario:**
  Buscamos nuestro código en vocabularios estándar
  Ej. ICD10CM o ATC

- **Source_to_concept_map:**
  Tabla intermedia con nuestros códigos locales y el concept_id asignado
  Ej. Códigos pfc, códigos de vacunas, tipo de visita (códigos locales)

- **Manual:**
  Asignamos manualmente en el script dónde irá cada código
  Ej. 4073182 Código asignado a las bajas laborales en observation

De SIDIAP a OMOP: Códigos

- **Source_to_concept_map:**
  Tabla intermedia con nuestros códigos locales y el concept_id asignado
  Ej. Códigos pfc, códigos de vacunas, tipo de visita (códigos locales)

source_code	source_concept_id	source_vocabulary_id	source_code_description	target_concept_id	target_vocabulary_id	valid_start_date	valid_end_date
ALRIS	0	None	Alcohol risk	432.456	SNOMED	1970-01-01	2099-12-31 GMT+01:00
A00039	0	None	Immunoglobulina antihepatitis B	501.343	RxNorm	1970-01-01	2099-12-31 GMT+01:00
A00010	0	None	Meningocci¿½cica A	509.079	RxNorm	1970-01-01	2099-12-31 GMT+01:00
A00011	0	None	Meningocci¿½cica C conjugada	509.081	RxNorm	1970-01-01	2099-12-31 GMT+01:00
A00020	0	None	Hepatitis B	528.323	RxNorm	1970-01-01	2099-12-31 GMT+01:00
686709	0	None	Hepatitis B Surface Antigen Vaccine	528.323	RxNorm	1970-01-01	2099-12-31 GMT+01:00
A00001	0	None	Difti¿½ria	529.303	RxNorm	1970-01-01	2099-12-31 GMT+01:00
A00002	0	None	Ti¿½tanus	529.411	RxNorm	1970-01-01	2099-12-31 GMT+01:00
A00038	0	None	Immunoglobulina Anti - D (Rh)	535.714	RxNorm	1970-01-01	2099-12-31 GMT+01:00
652774	0	None	TAMSULOSINA EDIGEN 0.4 MG CAPSULAS DURAS DE LIE	587.557	RxNorm Extension	2018-08-02	2099-12-31 GMT+01:00
652886	0	None	TAMSULOSINA ZENTIVA 0.4 MG CAPSULAS DURAS DE LI	587.557	RxNorm Extension	2018-08-02	2099-12-31 GMT+01:00

Source code	Source code description	Target concept_id
ALRIS	Alcohol Risk	432456
A00020	Hepatitis B	528323
A00001	Diftèria	529303

De SIDIAP a OMOP: Códigos

- **Usagi**
  Herramienta de soporte para encontrar códigos de mapeo por descripción (OHDSI)

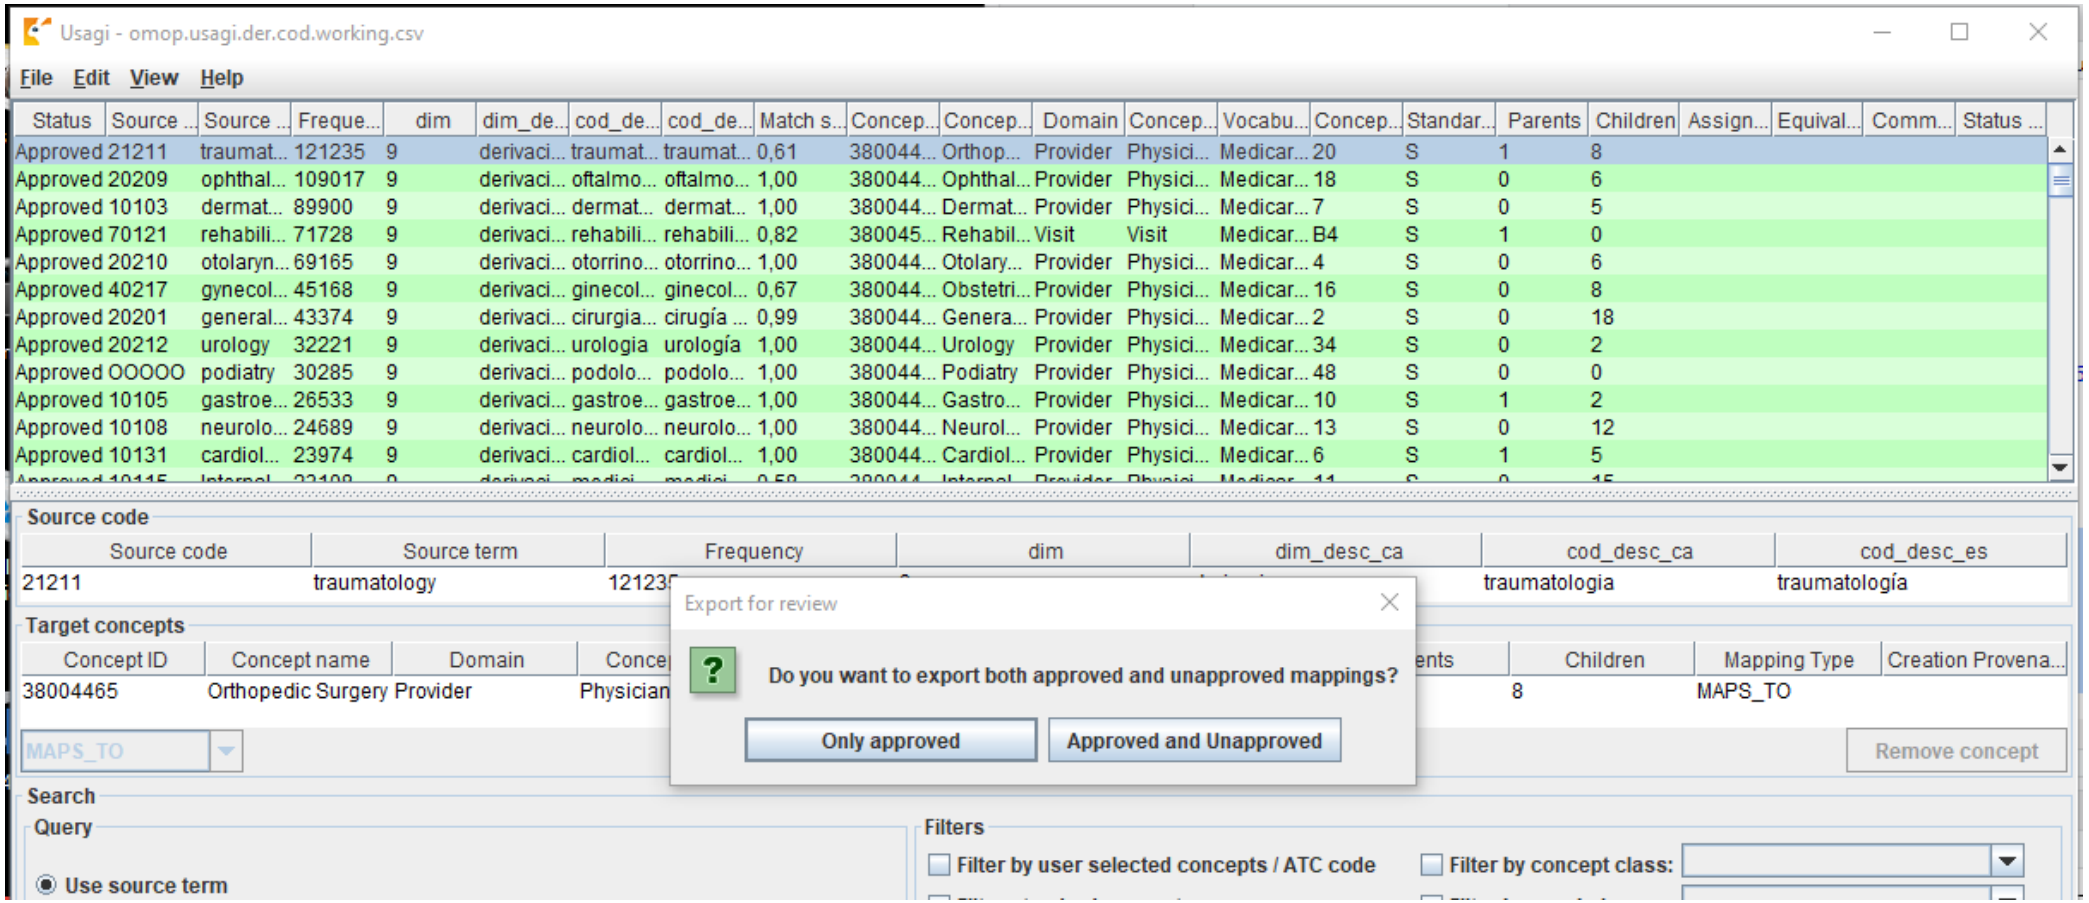

Tablas OMOP (Campos de las tablas)

- Tabla **PERSON**

Se mapea desde **població**

Person_id: identificador único de la persona que lo relaciona con el resto de las tablas

Gender_concept_id:

D -> 8532 (Female)
H -> 8507 (Male)

Gender_source_value: D, H

Year_of_birth, month_of_birth, day_of_birth:

Fecha de nacimiento (En SIDIAP-OMOP todos nacen el día 1)

Tablas OMOP (Campos de las tablas)

- Tabla **OBSERVATION_PERIOD**

Se mapea desde **població**

Observation_period_id: identificador único del período de observación.

En SIDIAP hay uno y sólo un período de observación por persona

Person_id: identificador único de la persona que lo relaciona con el resto de tablas

Observation_period_start_date, observation_period_end_date:

Entra, surt de la tabla població

Tablas OMOP (Campos de las tablas)

- Tabla **DEATH**

Se mapea desde **població**

Person_id: identificador único de la persona que lo relaciona con el resto de tablas

Death_date:

surt de la tabla població para personas con situació ‘D’

Tablas OMOP (Campos de las tablas)

- Tabla **VISIT_OCCURRENCE**

Se mapea desde **visites** y **cmbdh_dx**

Person_id: identificador único de la persona que lo relaciona con el resto de tablas

Visit_concept_id: Tipo de visita

9202 Outpatient visit

581476 Home Visit

9201 Inpatient visit (només CMBD)

32037 Intensive Care (només CMBD)

Visit_type_concept_id:

32817 EHR (Primària)

32829 EHR Inpatient Note (CMBD)

Visit_start_date y **visit_end_date**:

Misma fecha de inicio y de final, excepto para CMBD

Tablas OMOP (Campos de las tablas)

- Tabla **CONDITION_OCCURRENCE**

Se mapea desde **problemes, baixes_laborals, embarassos**

Person_id: identificador único de la persona que lo relaciona con el resto de tablas

Condition_concept_id:

Código SNOMED estándar correspondiente al código ICD10CM

Condition_source_concept_id:

Código ICD10CM válido (NO estándar) en OMOP

Condition_source_value:

Código origen ICD10CM del problema

Prefijos: SL_ (bajas), PR_ (embarazos)

Condition_start_date y condition_end_date:

Siempre hay fecha de inicio, fecha final solo a veces

Condition_type_concept_id:

32817 EHR (tabla embarassos)

32840 EHR problem list (primaria)

32829 EHR Inpatient Note (CMBD)

Ejemplo:

Código ICD10CM J03.90 (source_value)

Condition_source_concept_id 45538473 (Acute tonsilitis, unspecified)

Condition_concept_id 24660 (Acute tonsilitis)

Tablas OMOP (Campos de las tablas)

- Tabla **PROCEDURE_OCCURRENCE (No sólo CMBD)**

Se mapea desde **proves, cmbdh_px**

Person_id: identificador único de la persona que lo relaciona con el resto de tablas

Procedure_concept_id:

Código SNOMED estándar correspondiente al código ICD10PCS, al ICD9Proc o al código local del procedimiento (proves)

Procedure_source_concept_id:

Código ICD10PCS o ICD9Proc válido (NO estándar) en OMOP

Procedure_source_value:

Código origen del procedimiento

Prefijos: RA, PD, IQ, MN, AP, ICD10PCS_, ICD9Proc_

Procedure_start_date y procedure_end_date:

Misma fecha inicio y final, excepto para CMBD

Procedure_type_concept_id:

32817 EHR

32829 EHR Inpatient Note (CMBD)

Exemple:

Código RA00080
(RX CADERA 1-2 PROYECCIONES (F Y P)
procedure_source_value)

procedure_source_concept_id 0

procedure_concept_id 37204743 (Código estándar)
(Plain X-ray of hip)

Tablas OMOP (Campos de las tablas)

- Tabla **PROCEDURE_OCCURRENCE (No sólo CMBD)**

¿¿Cómo mapeamos los códigos que no existen en ningún vocabulario??

Ejemplo:

Código RA00080
(RX CADERA 1-2 PROYECCIONES (F Y P) procedure_source_value)

procedure_source_concept_id 0

procedure_concept_id 40489372 (Ahora es no estándar)
(X-ray of bone of hip)

procedure_concept_id 37204743 (Código estándar)
(Plain X-ray of hip)

Source_to_concept_map (Tabla de equivalencias)

source_code	source_concept_id	source_vocabulary_id	source_code_description	target_concept_id	target_vocabulary_id	valid_start_date	valid_end_date
RA00080	0	None	rx hip projections 1-2 (f and p)	37.204.743	SNOMED	1970-01-01	2099-12-31 GMT+01:00

Tablas OMOP (Campos de las tablas)

- Tabla **DRUG_EXPOSURE**

Se mapea desde **farmacs_facturats, farmacs_prescrits, vacunes**

Person_id: identificador único de la persona que lo relaciona con el resto de tablas

Drug_concept_id: Código estándar del fármaco

(se mapea desde pfc para obtener dosis)

Drug_type_concept_id:

32839 EHR prescription issue record

32825 EHR dispensing record

32818 EHR administration record (Vacunes)

Drug_exposure_start_date y **drug_exposure_end_date:**
vacunas misma fecha inicio y final
prescripción fechas inicio y final como las de origen
facturación: end_date=start_date+30

Tablas OMOP (Campos de las tablas)

- Tabla **MEASUREMENT**

Se mapea desde **variables_clíniques, variables_analítiques, embaràs, ecos, test, Charlson**

Person_id: identificador único de la persona que lo relaciona con el resto de tablas

Measurement_concept_id: Código estándar de la medida

Measurement_source_value: Código original o valor original de la medida

Measurement_date: únicamente una fecha de la medida

Unit_concept_id, unit_source_value, value_as_string, value_as_number

Tablas OMOP (Campos de las tablas)

- Tabla **OBSERVATION**

Se mapea desde **variables_geosanitaries, variables_socioeconomiques, embaràs, ecos, tabaquisme, derivacions, baixes_laborals**

Person_id: identificador único de la persona que lo relaciona con el resto de tablas

Observation_concept_id: Código estándar de la observación

Observation_source_value: Código original o valor original de la observación

Observation_date: únicamente una fecha de la observación

Unit_concept_id, unit_source_value, value_as_string, value_as_number

Bases de datos SIDIAP-OMOP

- Tres bases de datos:

Omop:

Toda la información de primaria

Omop_test:

Muestra aleatoria de un 5% de la población de SIDIAP (445k en la versión 244t)

Omop_cmbd:

Añadidos diagnósticos y procedimientos del CMBD

De SIDIAP a OMOP: Controles de calidad

- Data Quality Dashboard

Comprueba que los códigos son válidos, estándar y del dominio adecuado

Que tenemos las tablas que toca con el formato correcto

Que las medidas y observaciones son plausibles y con las unidades adecuadas

Que no hay registros que no están asociados a personas que no existen

Category	Pass	Fail	Total	%Pass
Plausibility	742	10	752	99%
Conformance	824	1	825	100%
Completeness	407	6	413	99%
Total	**1973**	**17**	**1990**	**99%**

Y mucho más...

https://github.com/OHDSI/DataQualityDashboard

De SIDIAP a OMOP: Controles de calidad

- Data Quality Dashboard

Errores detectados en el último mapeo

	A	B	C	D	E	F	G	H	I	J	K
1	STATUS	TABLE	FIELD	CHECK	CATEGORY	SUBCATEGORY	LEVEL	NOTES	DESCRIPTION	% RECORDS	OBSERVACIONS
6	FAIL	CONDITION_OCCURRENCE	CONDITION_CONCEPT_ID	plausibleGender	Plausibility	Atemporal	CONCEPT	None	For a CONCEPT_ID 193437 (NEOPLASM OF UNCERTAIN BEHAVIOR OF FEMALE GENITAL ORGAN), the number and percent of records associated with patients with an implausible gender (correct gender = FEMALE). (Threshold=5%).	17.64%	error registre dades origen
15	FAIL	DRUG_ERA	DRUG_ERA_END_DATE	plausibleBeforeDeath	Plausibility	Temporal	FIELD	None	The number and percent of records with a date value in the DRUG_ERA_END_DATE field of the DRUG_ERA table that occurs after death. (Threshold=1%).	9.26%	This is generated from prescribed drugs with end of prescription after current date
21	FAIL	DRUG_EXPOSURE	DRUG_CONCEPT_ID	isStandardValidConcept	Conformance	Value	FIELD	None	The number and percent of records that do not have a standard, valid concept in the DRUG_CONCEPT_ID field in the DRUG_EXPOSURE table. (Threshold=0%).	0.02%	no son estandards o vàlids, cal mirar-ho a mà
22	FAIL	DRUG_EXPOSURE	DRUG_CONCEPT_ID	fkDomain	Conformance	Value	FIELD	None	The number and percent of records that have a value in the DRUG_CONCEPT_ID field in the DRUG_EXPOSURE table that do not conform to the DRUG domain. (Threshold=0%).	0.00%	no son estandards o vàlids, cal mirar-ho a mà
27	FAIL	MEASUREMENT	MEASUREMENT_CONCEPT_ID	plausibleUnitConceptIds	Plausibility	Atemporal	CONCEPT	Exists	The number and percent of records for a given CONCEPT_ID 3026361 (ERYTHROCYTES [#/VOLUME] IN BLOOD) with implausible units (i.e., UNIT_CONCEPT_ID NOT IN (32706,8785,8815,8931)). (Threshold=5%).	100.00%	Change measurement_concept_id to 3009542 (Hematocrit determination)
28	FAIL	MEASUREMENT	MEASUREMENT_CONCEPT_ID	plausibleUnitConceptIds	Plausibility	Atemporal	CONCEPT	Exists	The number and percent of records for a given CONCEPT_ID 3034639 (HEMOGLOBIN A1C [MASS/VOLUME] IN BLOOD) with implausible units (i.e., UNIT_CONCEPT_ID NOT IN (8713,8840,9579,8923)). (Threshold=5%).	100.00%	Change measurement_concept_id to 3005673 (Hemoglobin A1c measurement)

De SIDIAP a OMOP: Controles de calidad

- Data Quality Dashboard

Errores detectados en el último mapeo

STATUS	TABLE	FIELD	CHECK	CATEGORY	SUBCATEGORY	LEVEL	NOTES	DESCRIPTION	% RECORDS
FAIL	OBSERVATION	OBSERVATION_CONCEPT_ID	standardConceptRecordCompleteness	Completeness	None	FIELD	None	The number and percent of records with a value of 0 in the standard concept field OBSERVATION_CONCEPT_ID in the OBSERVATION table. (Threshold=5%).	14.43%

10 observaciones más frecuentes mapeadas a 0

#	Source Value	#Records	#Subjects
1	REGICOR	11,382,500	2,236,600
2	qmedea11	8,894,200	8,894,200
3	abs	8,894,200	8,894,200
4	medea11	8,894,200	8,894,200
5	medea	8,894,200	8,894,200
6	apo_far	8,894,200	8,894,200
7	Pfeiffer_Mental_State	2,757,900	870,900
8	BPAAT	2,668,500	1,398,400
9	RCV	2,190,700	743,300
10	TIRS	1,870,400	632,300

De SIDIAP a OMOP: Controles de calidad

- Data Quality Checks: 244t vs 232t

Important Notes
Data release
Birth and death dates
Observation periods
Pregnancies
Fact relationship
CDM tables
Visits
Procedures
Measurements
Observation
Drug exposure
Conditions & medications
Sex-specific diseases
Concepts mapping
Priority variables to map

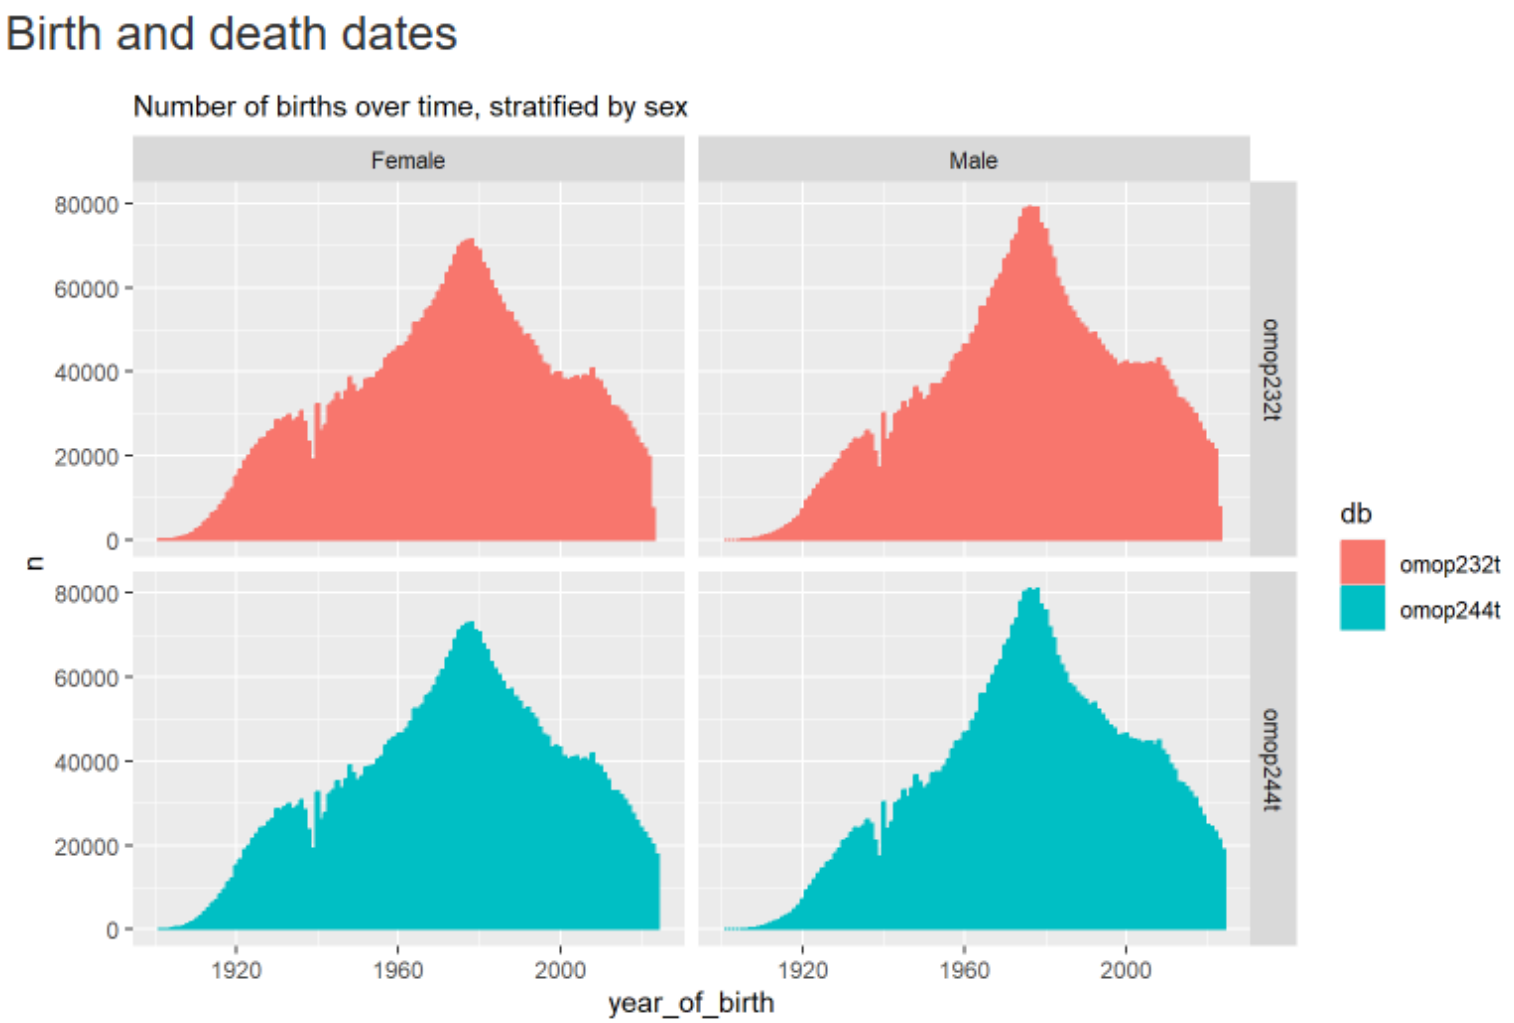

De SIDIAP a OMOP: Controles de calidad

- Data Quality Checks: 244t vs 232t

Fact relationship
CDM tables
Visits
Procedures
Measurements
Observation
Drug exposure
Conditions & medications
Sex-specific diseases
Concepts mapping
Priority variables to map

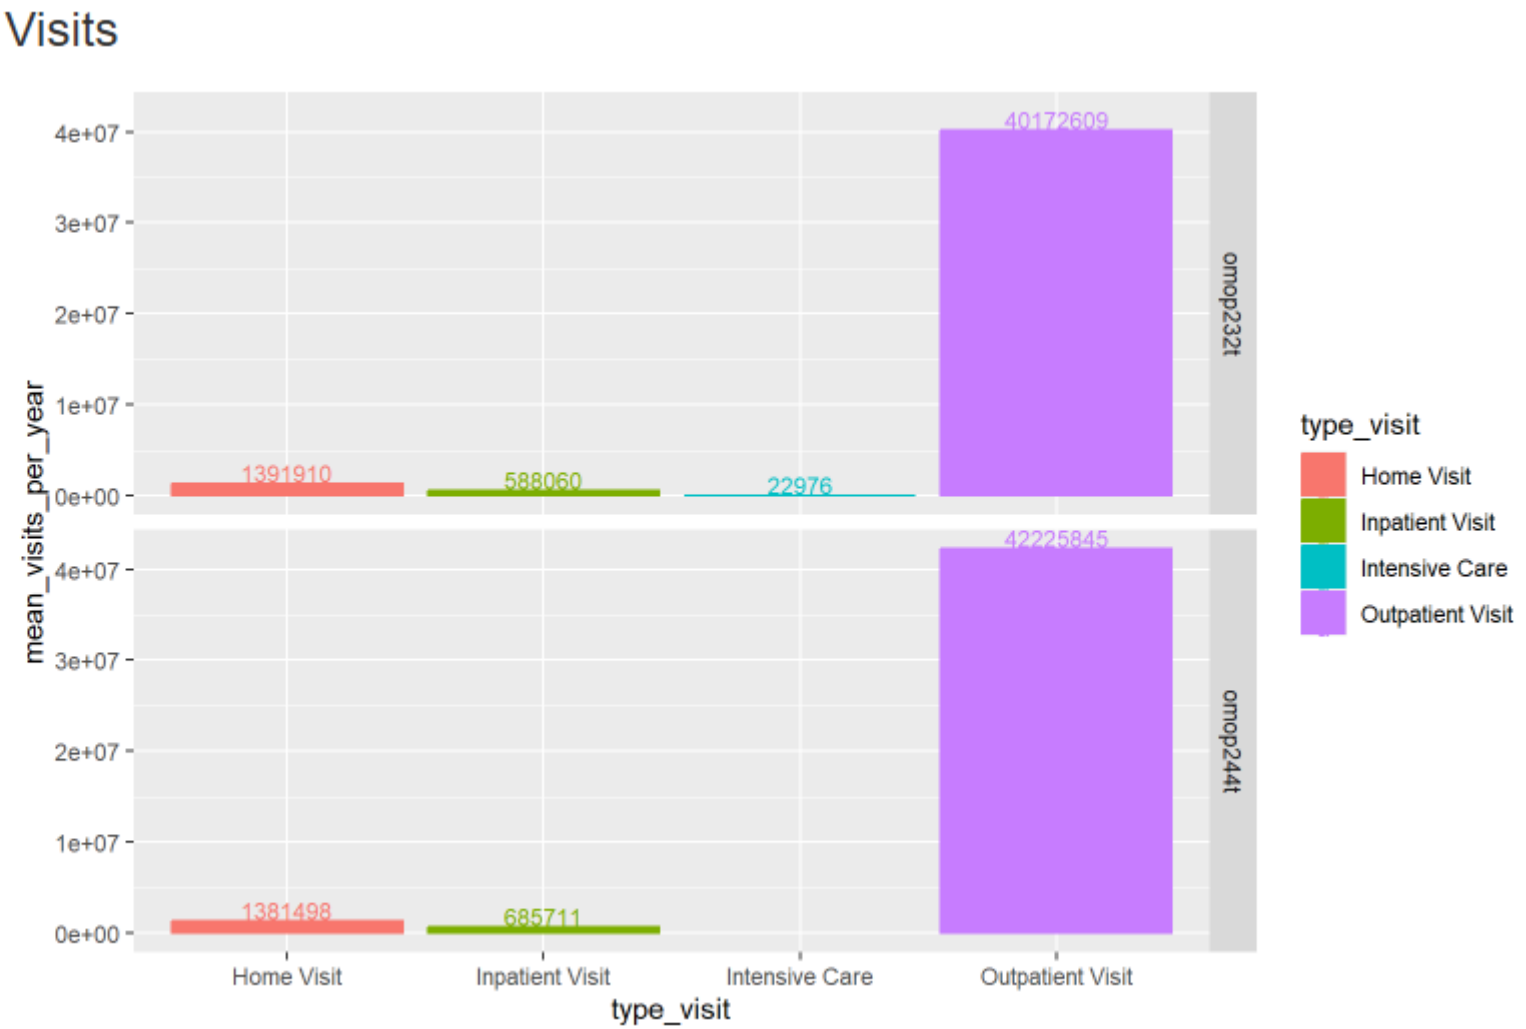

De SIDIAP a OMOP: Controles de calidad

- Data Quality Checks: 244t vs 232t

CDM tables
Visits
Procedures
Measurements
Observation
Drug exposure
Conditions & medications
Sex-specific diseases
Concepts mapping
Priority variables to map

Procedures

Records of procedures grouped by vocabulary id

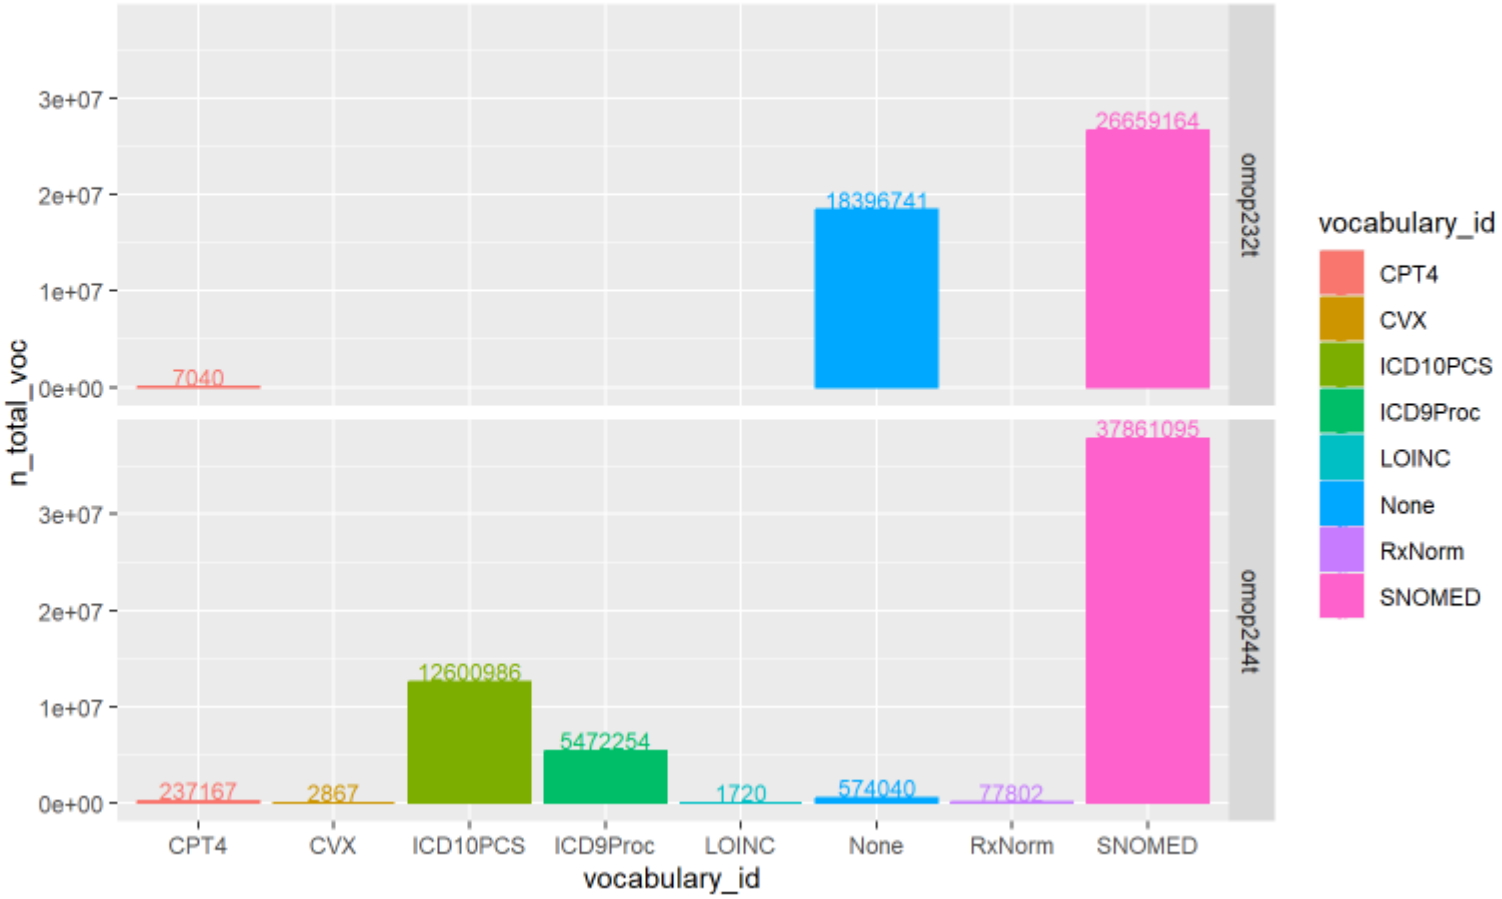

De SIDIAP a OMOP: Estado del mapeo

1.Mapping Completeness (2024 vs 2020)

Shows the percentage of codes that are mapped to the standardized vocabularies as well as the percentage of records.
Note: 1) for one-to-many mappings, the source codes will be counted multiple times so the reported total source codes could be bigger than actual number of unique source codes and 2) there are no OMOP observation source codes. ©

Domain	#Codes Source	#Codes Mapped	%Codes Mapped	#Records Source	#Records Mapped	%Records Mapped
Condition	59,990 (23,816)	59,990 (18,103)	100% (76.01%)	437,541,077 (141,078,491)	437,541,077 (136,042,879)	100% (96.43%)
Drug	36,438 (14,415)	14,990 (14,396)	**41.1%** **(99.87%)**	1,882,175,884 (266,968,327)	1,779,224,549 (266,196,325)	94.5% (99.71%)
Measurement	4,411 (539)	4,411 (435)	100% (80.71%)	1,765,549,311 (125,308,568)	1,765,549,311 (124,740,967)	100% (99.55%)
Measurement value	28 (14)	28 (13)	100% (92.86%)	28,584,102 (9,457,557)	28,584,102 (7,958,282)	100% (84.02%)
Procedure	40,089 (0)	39,700 (0)	99.0% (-)	56,796,886 (0)	56,222,846 (0)	99.0% (-)

Datos del mapeo de 2024 (Los del 2020 entre paréntesis)

Para más información: https://www.sidiap.org/

Data Resource Profile

Data Resource Profile: The Information System for Research in Primary Care (SIDIAP)

Martina Recalde ,[1,2†] Clara Rodríguez,[1†] Edward Burn ,[1,3] Marc Far,[1] Darío García,[1] Jordi Carrere-Molina,[1] Mencia Benítez,[1] Anna Moleras,[1] Andrea Pistillo,[1] Bonaventura Bolíbar,[1,2] María Aragón,[1*‡] and Talita Duarte-Salles [1‡]

[1]Fundació Institut Universitari per a la Recerca a l'Atenció Primària de Salut Jordi Gol i Gurina (IDIAPJGol), Barcelona, Spain, [2]Universitat Autònoma de Barcelona, Bellaterra, Spain and [3]Centre for Statistics in Medicine, NDORMS, University of Oxford, Oxford, UK

Transforming the Information System for Research in Primary Care (SIDIAP) in Catalonia to the OMOP Common Data Model and Its Use for COVID-19 Research

Berta Raventós[1,2,*], Sergio Fernández-Bertolín[1,*], María Aragón[1], Erica A Voss[3–5], Clair Blacketer[3–5], Leonardo Méndez-Boo[6], Martina Recalde[1], Elena Roel[1,2], Andrea Pistillo[1,7], Carlen Reyes[1], Sebastiaan van Sandijk[8], Lars Halvorsen[9], Peter R Rijnbeek[4,5], Edward Burn[1,10], Talita Duarte-Salles[1,4]

[1]Fundació Institut Universitari per a la recerca a l'Atenció Primària de Salut Jordi Gol i Gurina (IDIAPJGol), Barcelona, Spain; [2]Universitat Autònoma de Barcelona, Bellaterra (Cerdanyola del Vallès), Barcelona, Spain; [3]Janssen Pharmaceutical Research and Development, Titusville, NJ, USA; [4]Department of Medical Informatics, Erasmus University Medical Center, Rotterdam, the Netherlands; [5]OHDSI Collaborators, Observational Health Data Sciences and Informatics (OHDSI), New York, NY, USA; [6]Sistemes d'Informació dels Serveis d'Atenció Primària (SISAP), Institut Català de la Salut, Barcelona, Spain; [7]Universitat Pompeu Fabra, Barcelona, Spain; [8]Odysseus Data Services s.r.o., Prague, Czech Republic; [9]edenceHealth NV, Kontich, Belgium; [10]Centre for Statistics in Medicine, University of Oxford, Oxford, UK

¡Gracias por vuestra atención!

Para dudas o sugerencias:

sfernandez@idiapjgol.org