IncidencePrevalence R package: Uso y desarrollo

Berta Raventós, PhD
Erasmus Medical Center
b.raventosiroca@erasmusmc.nl

Índice

1. **Conceptos**
2. Interfaz y funciones principales
3. Validación
4. Elección de parámetros
5. Práctica

Conceptos

- **Incidencia:** tasa que mide la frecuencia con la que aparecen casos nuevos de una enfermedad en una población en riesgo, teniendo en cuenta el tiempo de exposición de cada individuo.

- **Prevalencia:** proporción de individuos en una población que tienen una enfermedad en un momento específico o durante un período determinado.

$$\text{Tasa de Incidencia} = \frac{\text{Nº de personas que contraen la enfermedad en un periodo de tiempo}}{\text{Suma del tiempo de seguimiento de todas las personas en riesgo durante ese periodo}}$$

$$P = \frac{\text{Nº de casos}}{\text{Población total}}$$

Conceptos

- **Incidencia:** tasa que mide la frecuencia con la que aparecen casos nuevos de una enfermedad en una población en riesgo, teniendo en cuenta el tiempo de exposición de cada individuo.

- **Prevalencia:** proporción de individuos en una población que tienen una enfermedad en un momento específico o durante un período determinado.

Objetivo:

- Facilitar análisis en BD mapeados a OMOP
- Ofrecer flexibilidad para responder a diferentes preguntas de investigación

Conceptos

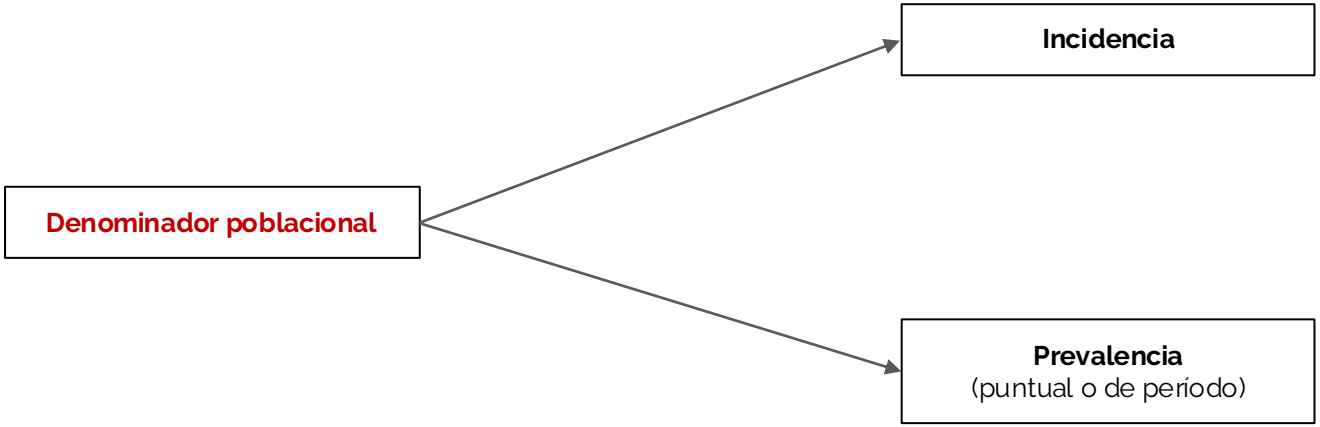
Denominador poblacional
Incidencia
Prevalencia
(puntual o de período)

Denominador poblacional

$$\text{Tasa de Incidencia} = \frac{\text{Nº de personas que contraen la enfermedad en un periodo de tiempo}}{\text{Suma del tiempo de seguimiento de todas las personas en riesgo durante ese periodo}}$$

$$P = \frac{\text{Nº de casos}}{\text{Población total}}$$

Denominador poblacional

Tiempo en observación

Período de tiempo en el que, si un paciente tuviera un evento de interés, ese evento sería registrado en la base de datos.

$$\text{Tasa de Incidencia} = \frac{\text{Nº de personas que contraen la enfermedad en un periodo de tiempo}}{\text{Suma del tiempo de seguimiento de todas las personas en riesgo durante ese periodo}}$$

$$P = \frac{\text{Nº de casos}}{\text{Población total}}$$

Escenario óptimo:

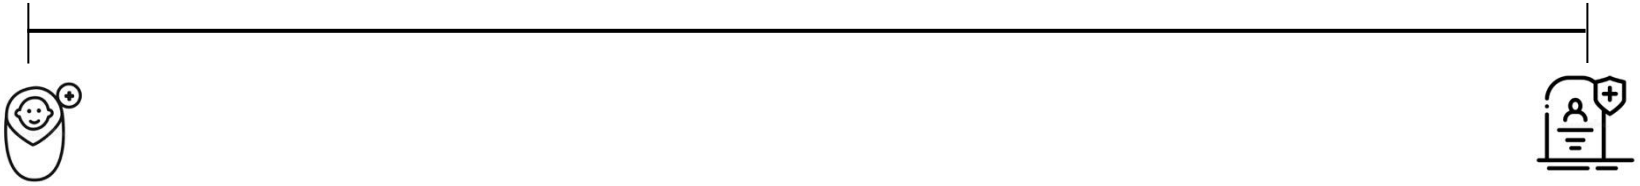

Denominador poblacional

Tiempo en observación

Período de tiempo en el que, si un paciente tuviera un evento de interés, ese evento sería registrado en la base de datos.

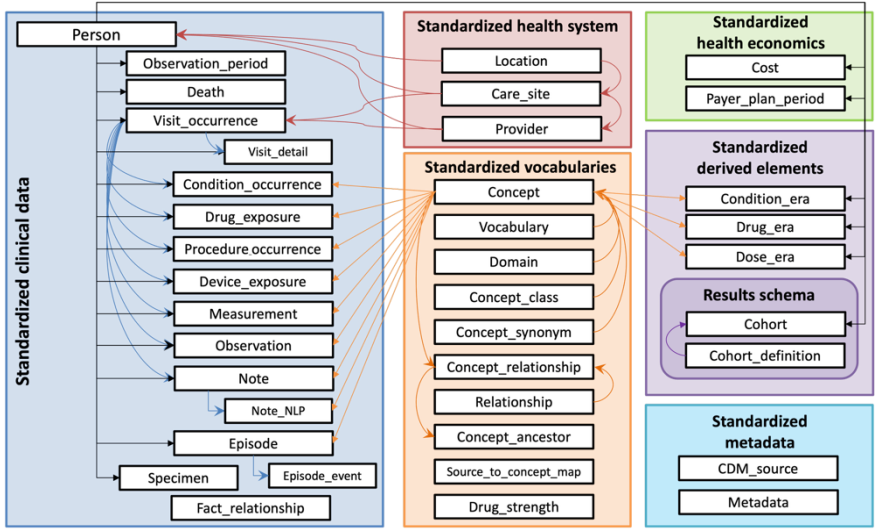

Denominador poblacional

Período de observación

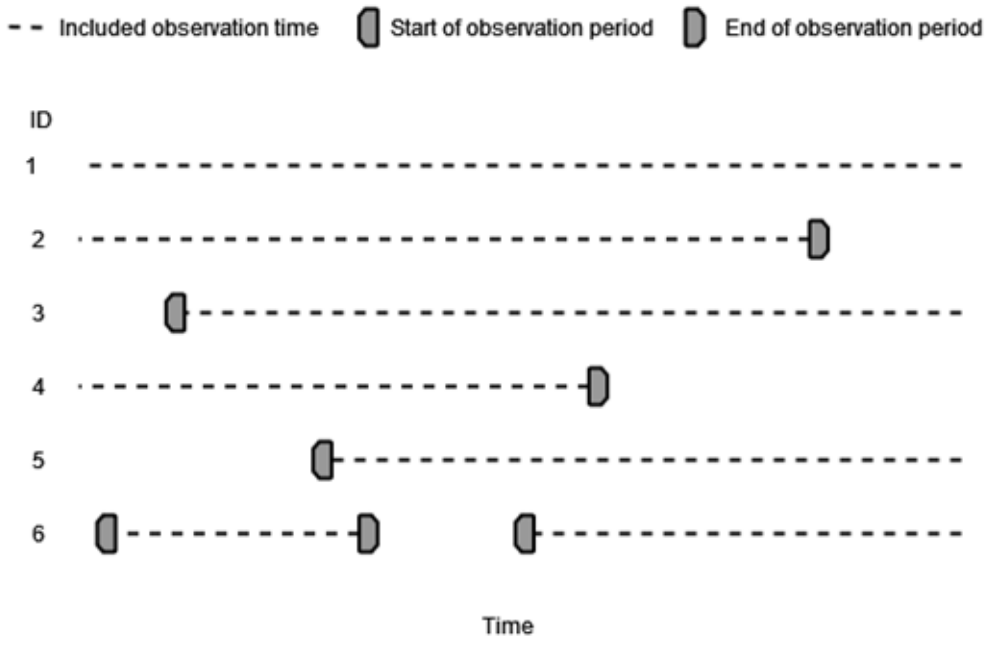

Denominador poblacional

Período de observación + Período de estudio

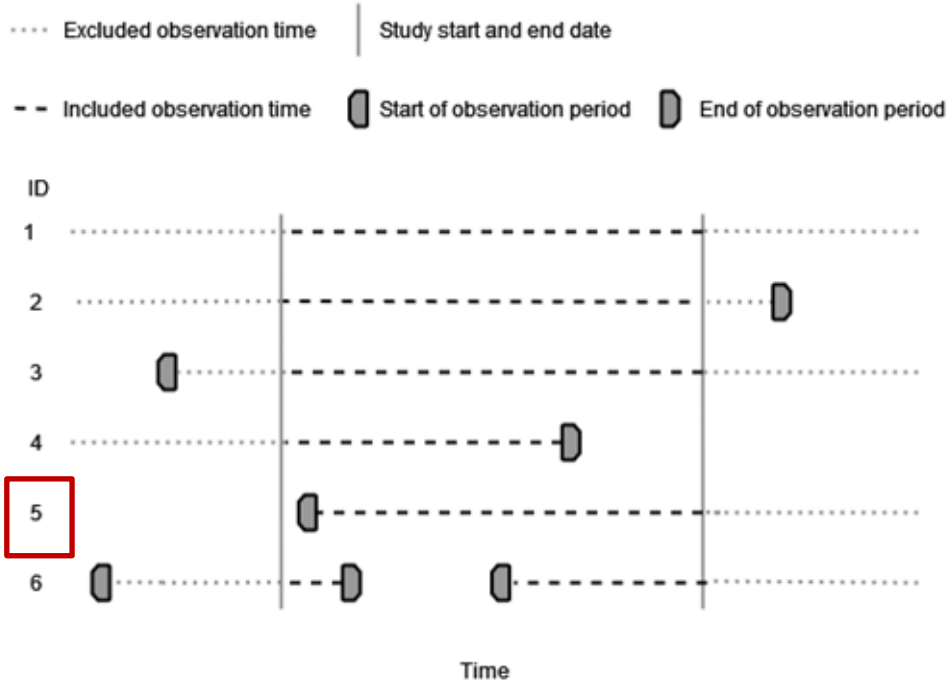

Denominator population

Período de observación + Período de estudio + Historia previa

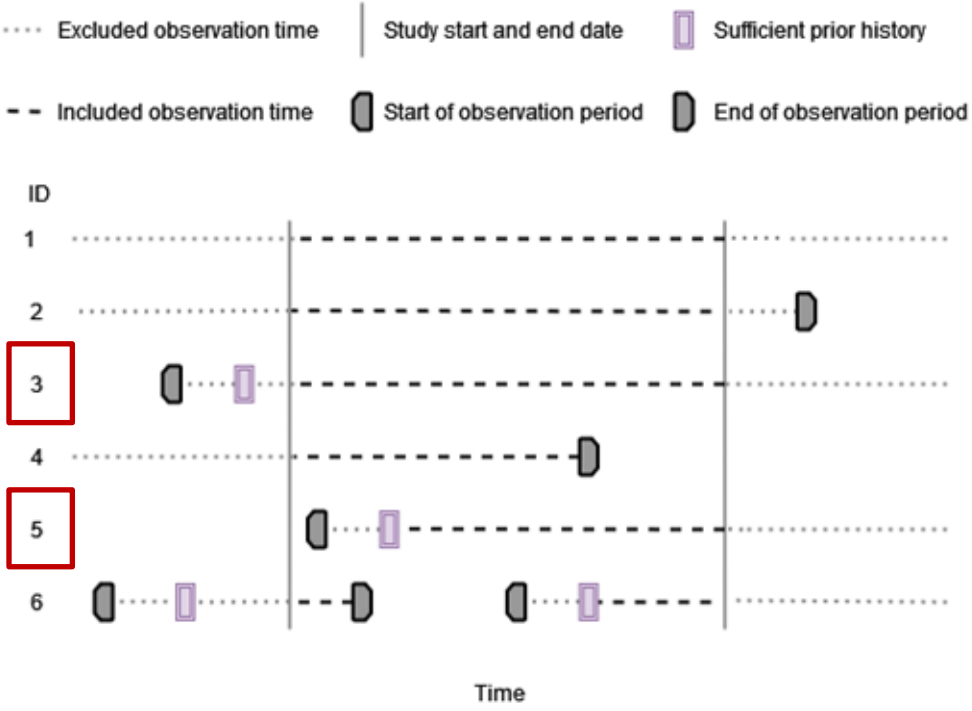

Los pacientes pueden entrar y salir en momentos diferentes

Denominator population

Período de observación + Período de studio + Historia previa + Edad/sexo

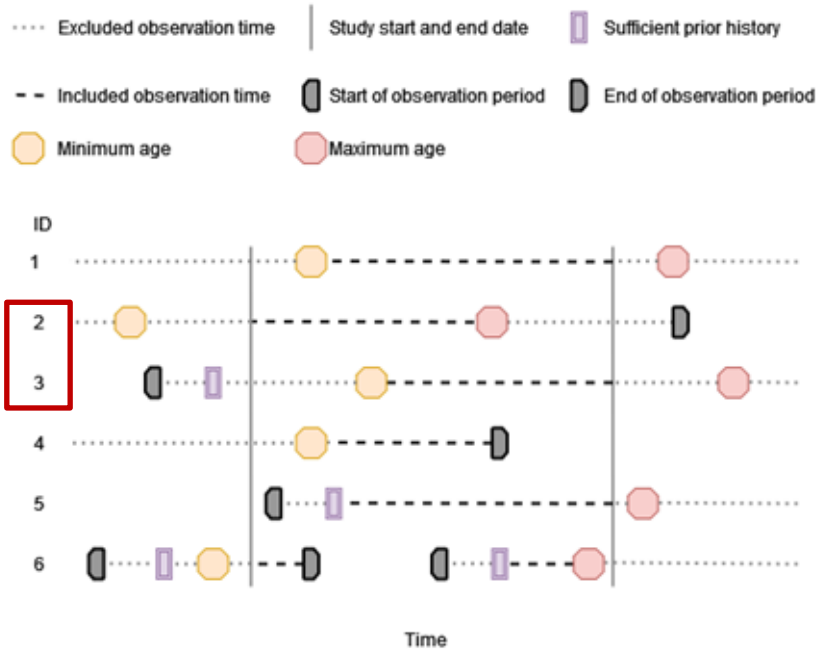

Los pacientes pueden entrar y salir en momentos diferentes

Denominator population

Período de observación + Período de studio + Historia previa + Edad/sexo

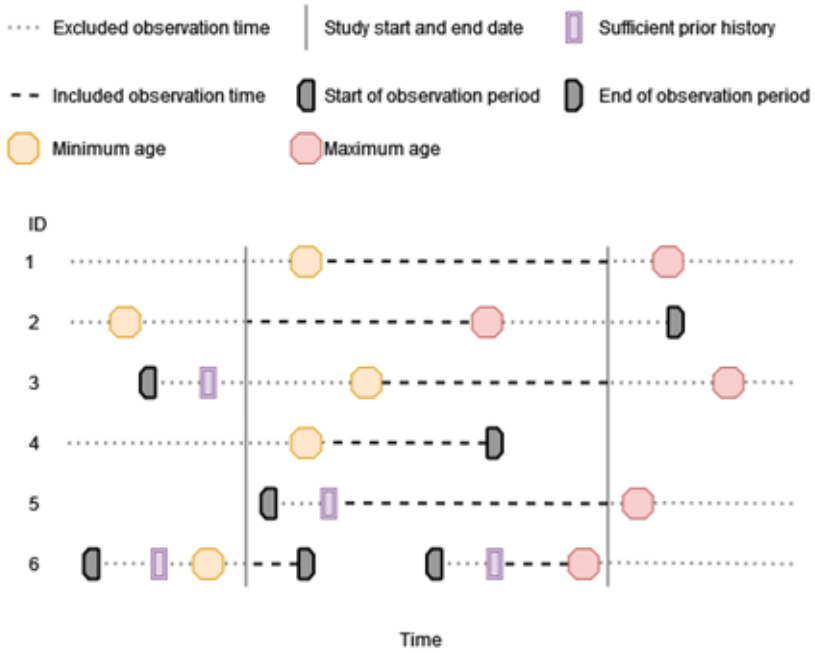

Entran cuándo (fecha máxima):

- Fecha inicio del estudio
- Fecha en la que tienen suficiente historia previa
- Fecha en la que cumplen la edad mínima

Salen cuándo (fecha mínima):

- Fecha fin del estudio
- Fecha en la que termina la observación
- Fecha en la que cumplen la edad máxima

Conceptos

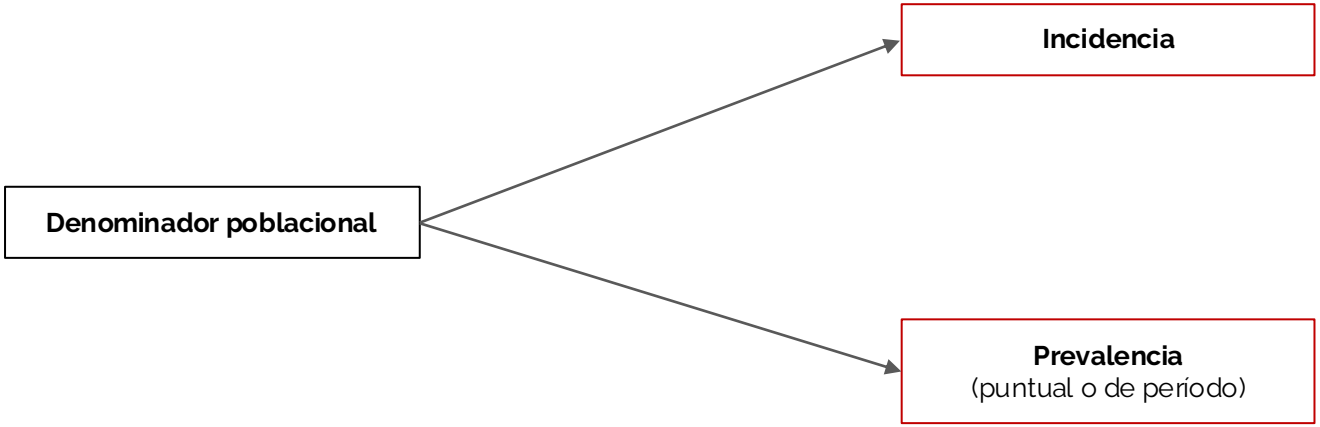
Denominador poblacional
Incidencia
Prevalencia
(puntual o de período)

Incidencia

No washout

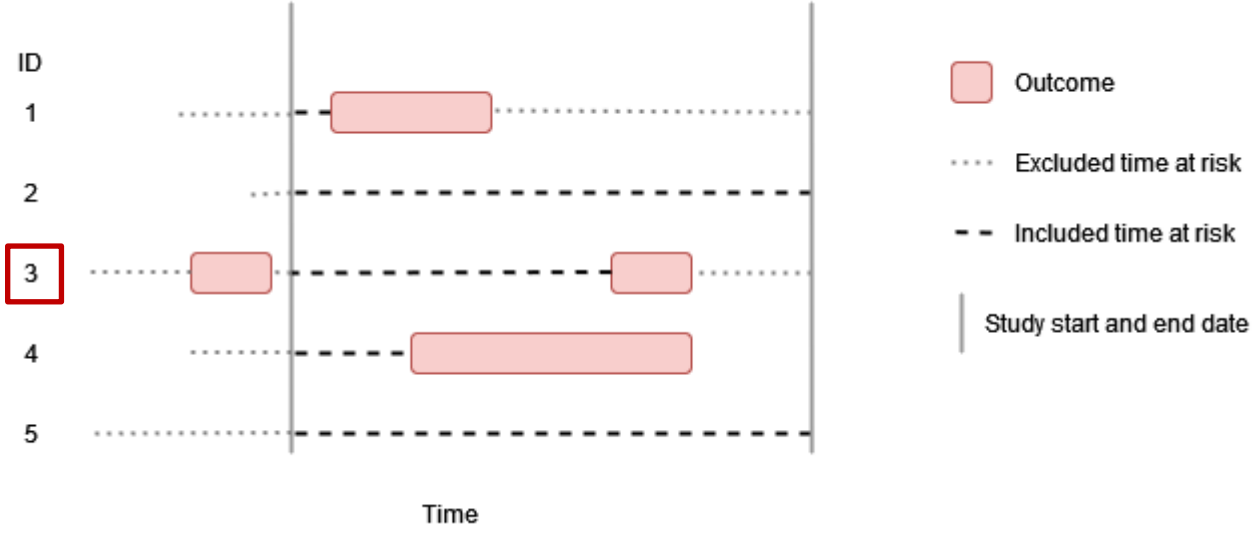

Incidencia

Washout all history

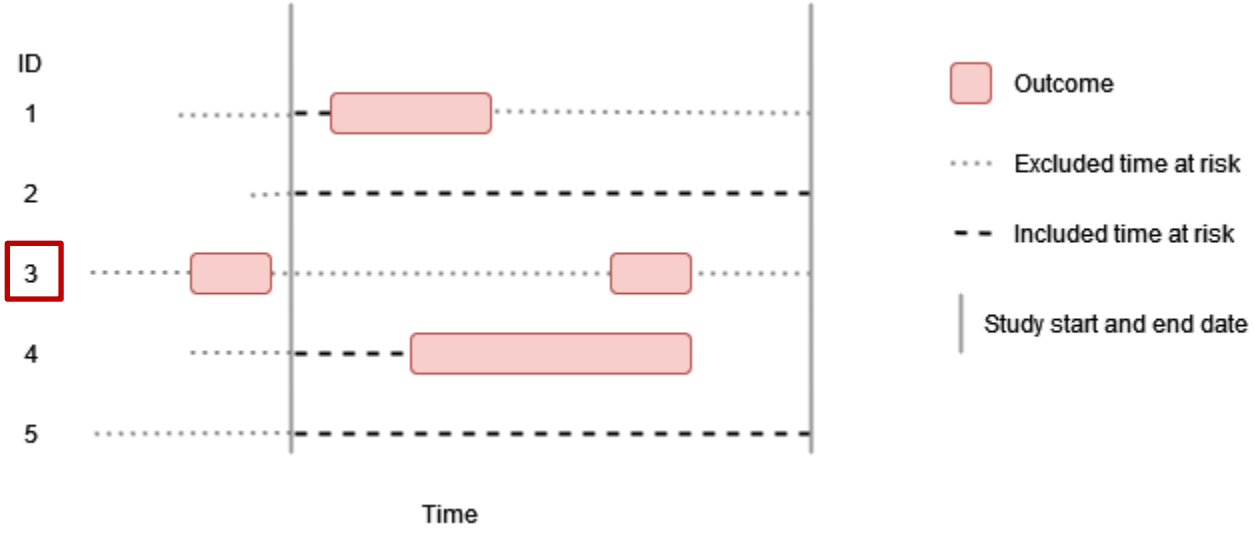

Incidencia

Some washout

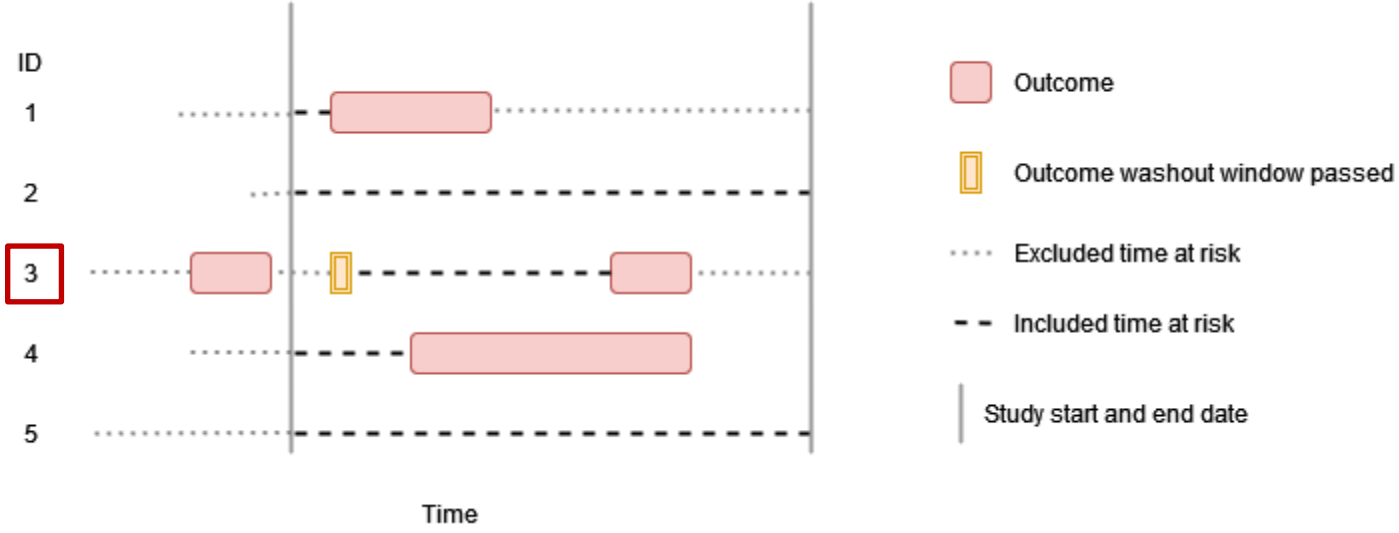

Incidencia

Some washout, **repetitive events**

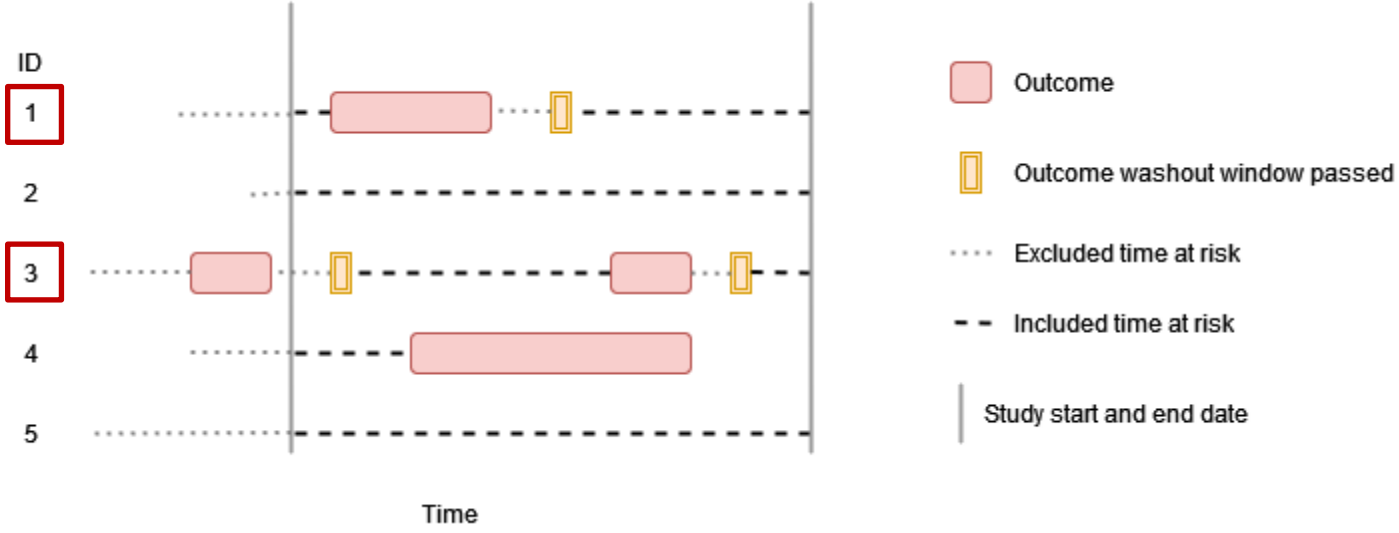

Prevalencia

Puntual (i.e. *point prevalence*)

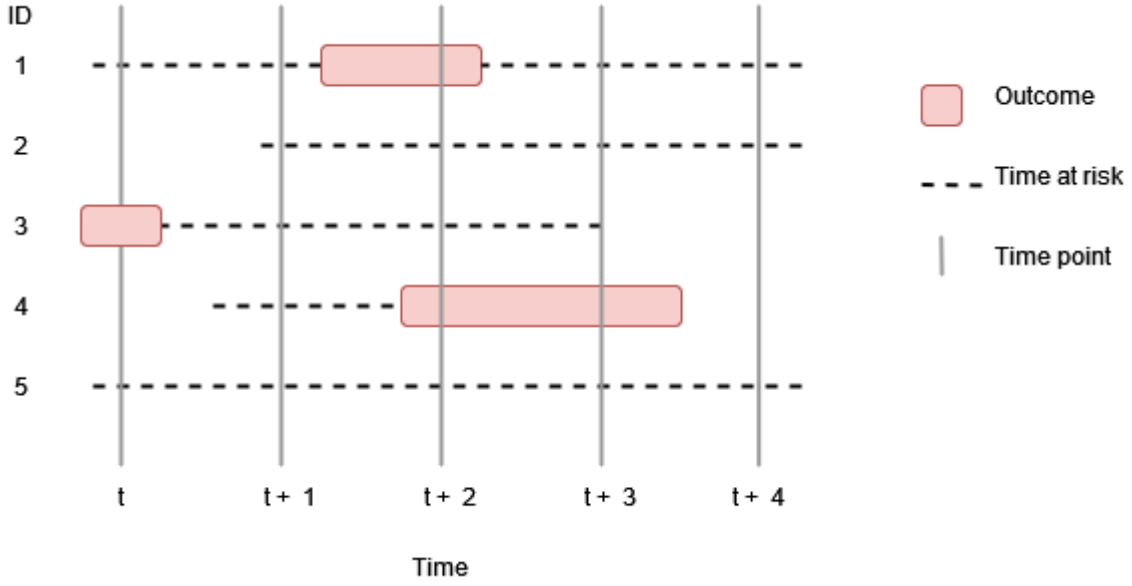

Prevalencia

De período (i.e., *period prevalence*)

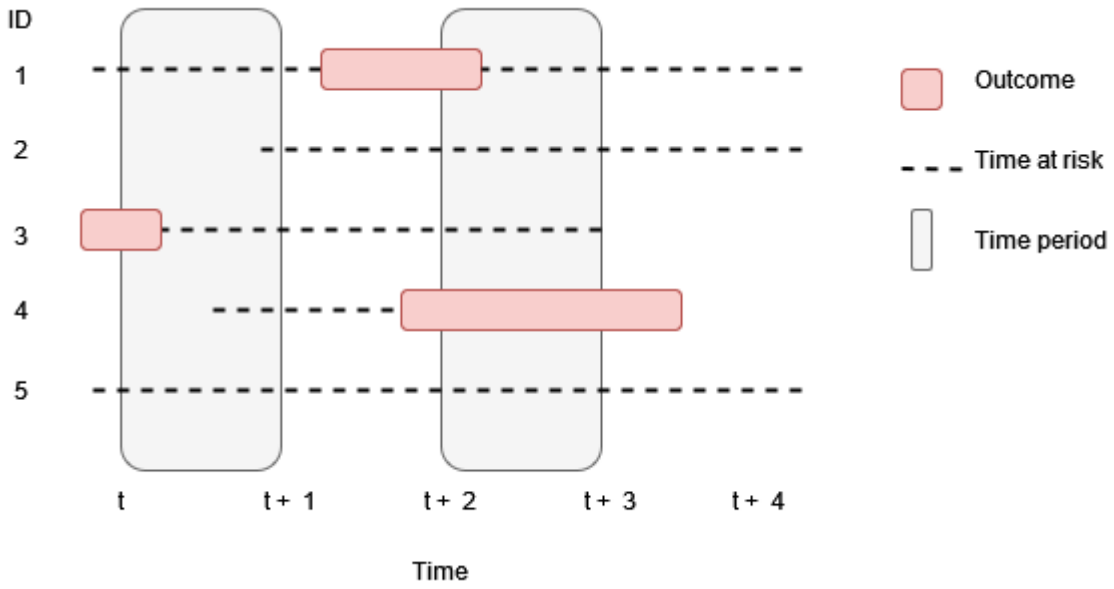

Índice

1. Conceptos
2. **Interfaz y funciones principales**
3. Validación
4. Elección de parámetros
5. Práctica

Interfaz

```
> print(cdm)

── # OMOP CDM reference (duckdb) of Synthea
• omop tables: person, observation_period, visit_occurrence, visit_detail, condition_occurrence, drug_exposure,
procedure_occurrence, device_exposure, measurement, observation, death, note, note_nlp, specimen, fact_relationship,
location, care_site, provider, payer_plan_period, cost, drug_era, dose_era, condition_era, metadata, cdm_source, concept,
vocabulary, domain, concept_class, concept_relationship, relationship, concept_synonym, concept_ancestor,
source_to_concept_map, drug_strength, cohort_definition, attribute_definition
• cohort tables: -
• achilles tables: -
• other tables:
```

cdm

Objeto con todas las tablas de nuestra BD

Interfaz

```
> print(cdm)

── # OMOP CDM reference (duckdb) of Synthea
• omop tables: person, observation_period, visit_occurrence, visit_detail, condition_occurrence, drug_exposure,
procedure_occurrence, device_exposure, measurement, observation, death, note, note_nlp, specimen, fact_relationship,
location, care_site, provider, payer_plan_period, cost, drug_era, dose_era, condition_era, metadata, cdm_source, concept,
vocabulary, domain, concept_class, concept_relationship, relationship, concept_synonym, concept_ancestor,
source_to_concept_map, drug_strength, cohort_definition, attribute_definition
• cohort tables: -
• achilles tables: -
• other tables:
```

cdm

Objeto con todas las tablas de nuestra BD

Cohortes

Interfaz

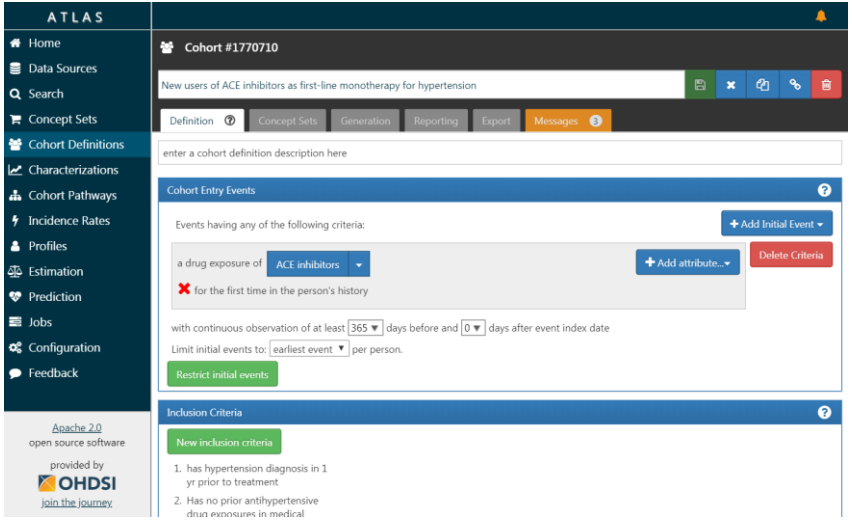

Cohortes

Construcción cohortes: Concept set + Lógica temporal

Diferentes herramientas (e.g. ATLAS, R)

Interfaz

Cohortes

```
> print(cdm)

── # OMOP CDM reference (duckdb) of Synthea ──
• omop tables: person, observation_period, visit_occurrence, visit_detail, condition_occurrence, drug_exposure,
procedure_occurrence, device_exposure, measurement, observation, death, note, note_nlp, specimen, fact_relationship,
location, care_site, provider, payer_plan_period, cost, drug_era, dose_era, condition_era, metadata, cdm_source, concept,
vocabulary, domain, concept_class, concept_relationship, relationship, concept_synonym, concept_ancestor,
source_to_concept_map, drug_strength, cohort_definition, attribute_definition
• cohort tables: -
• achilles tables: -
• other tables:
```

	cohort_definition_id	subject_id	cohort_start_date	cohort_end_date
	<int>	<chr>	<date>	<date>
1	1	1	1958-12-18	1979-05-15
2	1	2	1967-04-25	1991-11-08
3	1	3	1985-10-12	2027-05-02
4	1	4	1985-02-02	2052-08-14
5	1	6	1960-09-25	2054-10-30
6	1	8	1962-10-21	2019-04-25
7	1	10	1954-02-19	2051-01-16
8	1	11	1977-01-28	2067-02-09
9	1	12	1964-06-15	2004-11-22
10	1	13	1963-05-14	2028-06-20

Denominador

Crear datos sintéticos

```
cdm <- mockIncidencePrevalence(
  sampleSize = 20000,
  earliestObservationStartDate = as.Date("1960-01-01"),
  minOutcomeDays = 365,
  outPre = 0.3
)
```

Generar denominador

```
cdm <- generateDenominatorCohortSet(
  cdm = cdm, name = "denominator",
  cohortDateRange = c(as.Date("1990-01-01"), as.Date("2009-12-31")),
  ageGroup = list(c(0, 150)),
  sex = "Both",
  daysPriorObservation = 0
)
```

Opciones de diseño

```
cdm$denominator %>%
  glimpse()
#> Rows: ??
#> Columns: 4
#> Database: DuckDB v1.2.0 [unknown@Linux 6.8.0-1021-azure:R 4.4.3/:memory:]
#> $ cohort_definition_id <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
#> $ subject_id           <int> 1, 3, 10, 12, 14, 16, 18, 19, 20, 22, 23, 25, 27,
#> $ cohort_start_date    <date> 1991-08-05, 2007-02-16, 2009-04-21, 1992-01-28,
#> $ cohort_end_date      <date> 1996-01-10, 2007-12-09, 2009-12-31, 1999-08-18,
```

Source: https://darwin-eu.github.io/IncidencePrevalence/articles/a02_Creating_denominator_populations.html

Incidencia

```r
inc <- estimateIncidence(
  cdm = cdm,
  denominatorTable = "denominator",
  outcomeTable = "outcome",
  interval = "years",
  outcomeWashout = Inf,
  repeatedEvents = FALSE
)

inc %>%
  glimpse()
#> Rows: 184
#> Columns: 13
#> $ result_id        <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
#> $ cdm_name         <chr> "mock", "mock", "mock", "mock", "mock", "mock", "mocl
#> $ group_name       <chr> "denominator_cohort_name &&& outcome_cohort_name", "
#> $ group_level      <chr> "denominator_cohort_1 &&& cohort_1", "denominator_col
#> $ strata_name      <chr> "overall", "overall", "overall", "overall", "overall"
#> $ strata_level     <chr> "overall", "overall", "overall", "overall", "overall"
#> $ variable_name    <chr> "Denominator", "Outcome", "Denominator", "Denominato
#> $ variable_level   <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N
#> $ estimate_name    <chr> "denominator_count", "outcome_count", "person_days",
#> $ estimate_type    <chr> "integer", "integer", "numeric", "numeric", "numeric"
#> $ estimate_value   <chr> "2168", "107", "659947", "1806.836", "5921.954", "485
#> $ additional_name  <chr> "incidence_start_date &&& incidence_end_date &&& anal
#> $ additional_level <chr> "1990-01-01 &&& 1990-12-31 &&& years", "1990-01-01 &&
```

Calcular incidencia

Cohortes creadas previamente

Opciones de diseño

Source: https://darwin-eu.github.io/IncidencePrevalence/articles/a05_Calculating_incidence.html

Incidencia

```r
inc <- estimateIncidence(
  cdm = cdm,
  denominatorTable = "denominator",
  outcomeTable = "outcome",
  interval = "years",
  outcomeWashout = Inf,
  repeatedEvents = FALSE
)
```

Calcular incidencia

Cohortes creadas previamente

Opciones de diseño

```r
inc %>%
  glimpse()
#> Rows: 184
#> Columns: 13
#> $ result_id        <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
#> $ cdm_name         <chr> "mock", "mock", "mock", "mock", "mock", "mock", "mocl
#> $ group_name       <chr> "denominator_cohort_name &&& outcome_cohort_name", "
#> $ group_level      <chr> "denominator_cohort_1 &&& cohort_1", "denominator_col
#> $ strata_name      <chr> "overall", "overall", "overall", "overall", "overall"
#> $ strata_level     <chr> "overall", "overall", "overall", "overall", "overall"
#> $ variable_name    <chr> "Denominator", "Outcome", "Denominator", "Denominato
#> $ variable_level   <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N
#> $ estimate_name    <chr> "denominator_count", "outcome_count", "person_days",
#> $ estimate_type    <chr> "integer", "integer", "numeric", "numeric", "numeric"
#> $ estimate_value   <chr> "2168", "107", "659947", "1806.836", "5921.954", "485
#> $ additional_name  <chr> "incidence_start_date &&& incidence_end_date &&& ana
#> $ additional_level <chr> "1990-01-01 &&& 1990-12-31 &&& years", "1990-01-01 &&
```

```r
plotIncidence(inc)
```

Visualización

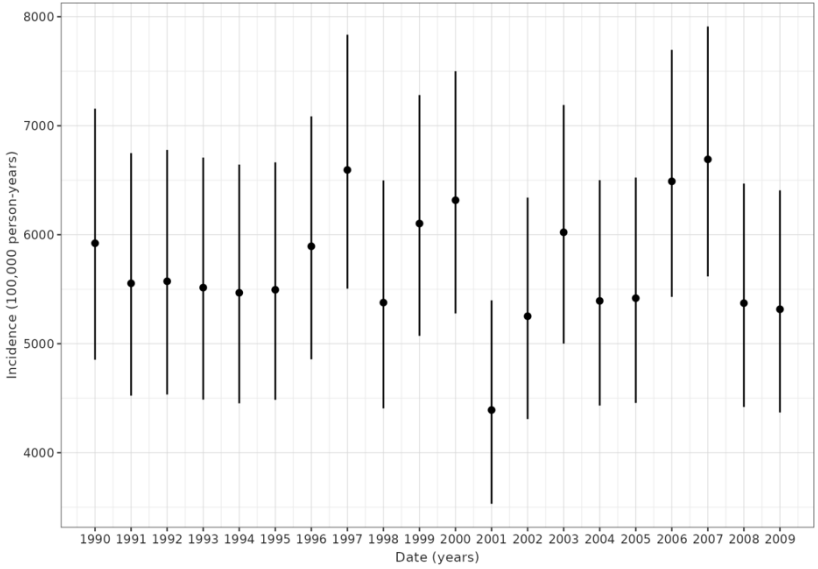

Source: https://darwin-eu.github.io/IncidencePrevalence/articles/a05_Calculating_incidence.html

Prevalencia “puntual”

```r
prev <- estimatePointPrevalence(
  cdm = cdm,
  denominatorTable = "denominator",
  outcomeTable = "outcome",
  interval = "Years",
  timePoint = "middle"
)
```

Calcular prevalencia

Cohortes creadas previamente

Opciones de diseño

```r
prev %>%
  glimpse()
#> Rows: 144
#> Columns: 13
#> $ result_id        <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
#> $ cdm_name         <chr> "mock", "mock", "mock", "mock", "mock", "mock", "mock
#> $ group_name       <chr> "denominator_cohort_name &&& outcome_cohort_name", "c
#> $ group_level      <chr> "denominator_cohort_1 &&& cohort_1", "denominator_coh
#> $ strata_name      <chr> "overall", "overall", "overall", "overall", "overall"
#> $ strata_level     <chr> "overall", "overall", "overall", "overall", "overall"
#> $ variable_name    <chr> "Denominator", "Outcome", "Outcome", "Outcome", "Outc
#> $ variable_level   <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N
#> $ estimate_name    <chr> "denominator_count", "outcome_count", "prevalence", "
#> $ estimate_type    <chr> "integer", "integer", "numeric", "numeric", "numeric"
#> $ estimate_value   <chr> "2160", "76", "0.03519", "0.0282", "0.04382", "2161",
#> $ additional_name  <chr> "prevalence_start_date &&& prevalence_end_date &&& an
#> $ additional_level <chr> "1990-07-01 &&& 1990-07-01 &&& years", "1990-07-01 &&
```

```r
plotPrevalence(prev, line = FALSE)
```

Visualización

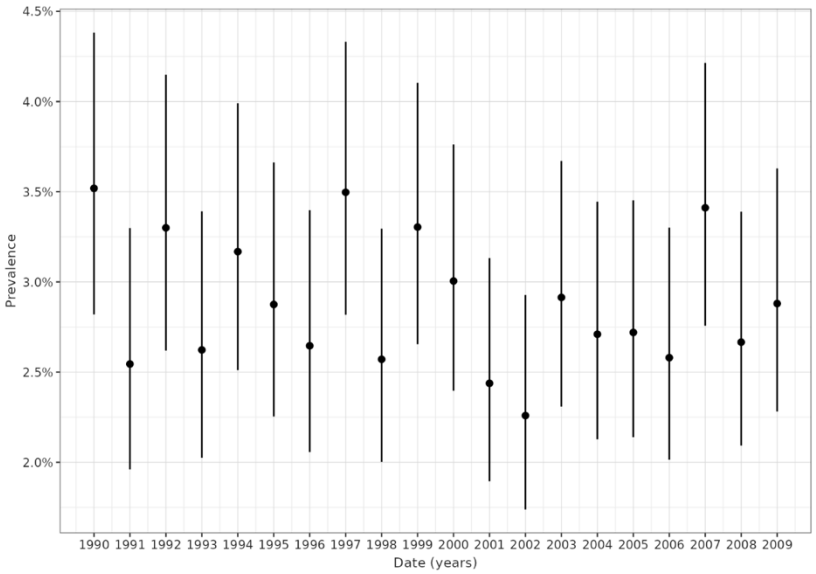

Source: https://darwin-eu.github.io/IncidencePrevalence/articles/a04_Calculating_prevalence.html

Prevalencia “de período”

```r
prev <- estimatePeriodPrevalence(
  cdm = cdm,
  denominatorTable = "denominator",
  outcomeTable = "outcome",
  interval = "Months",
  fullContribution = FALSE
)

prev %>%
  glimpse()
#> Rows: 1,244
#> Columns: 13
#> $ result_id        <int> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,
#> $ cdm_name         <chr> "mock", "mock", "mock", "mock", "mock", "mock", "mock
#> $ group_name       <chr> "denominator_cohort_name &&& outcome_cohort_name", "c
#> $ group_level      <chr> "denominator_cohort_1 &&& cohort_1", "denominator_coh
#> $ strata_name      <chr> "overall", "overall", "overall", "overall", "overall"
#> $ strata_level     <chr> "overall", "overall", "overall", "overall", "overall"
#> $ variable_name    <chr> "Denominator", "Outcome", "Outcome", "Outcome", "Outc
#> $ variable_level   <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N
#> $ estimate_name    <chr> "denominator_count", "outcome_count", "prevalence", "
#> $ estimate_type    <chr> "integer", "integer", "numeric", "numeric", "numeric"
#> $ estimate_value   <chr> "2176", "94", "0.0432", "0.03543", "0.05258", "2171",
#> $ additional_name  <chr> "prevalence_start_date &&& prevalence_end_date &&& an
#> $ additional_level <chr> "1990-01-01 &&& 1990-01-31 &&& months", "1990-01-01 &

plotPrevalence(prev)
```

Calcular prevalencia

Cohortes creadas previamente

Opciones de diseño

Visualización

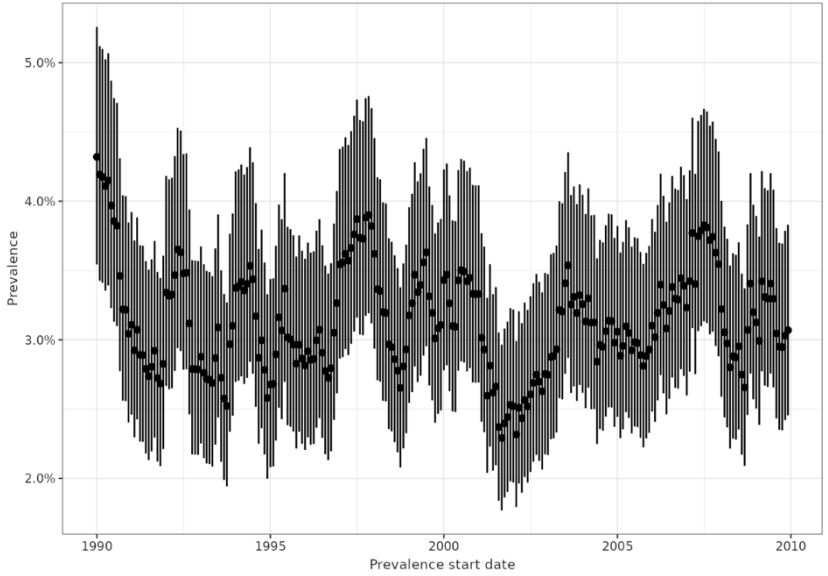

Source: https://darwin-eu.github.io/IncidencePrevalence/articles/a04_Calculating_prevalence.html

Muchas más funcionalidades....

1. Participantes excluidos en cada paso
2. Estratificar resultados usando otras variables (a parte de sexo y edad)
3. Restringir los participantes a una población concreta
4. Calcular incidencia/prevalencia en diferentes ventanas de tiempo

Y mucho más!

https://darwin-eu.github.io/IncidencePrevalence/reference/index.html

Funciones principales

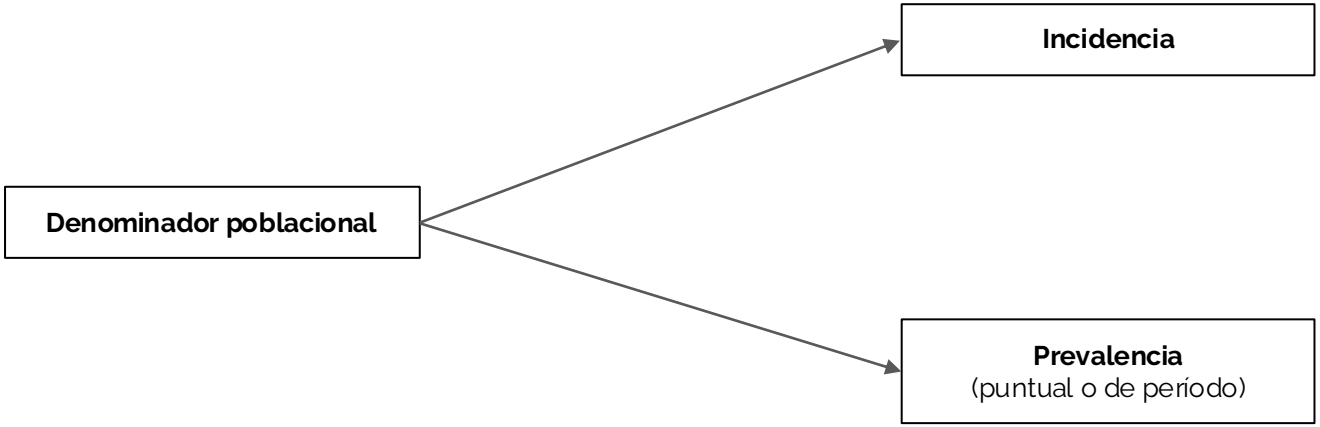

Funciones principales

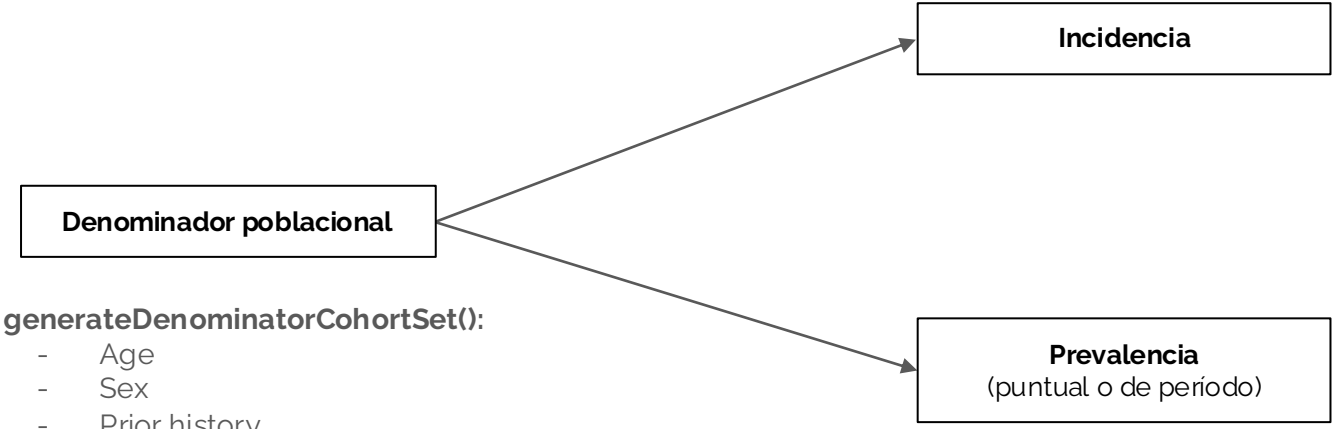

generateDenominatorCohortSet():

- Age
- Sex
- Prior history

Funciones principales

estimateIncidence():
- outcomeWashout
- repetitiveEvents

Incidencia → **plotIncidence()**

Denominador poblacional

generateDenominatorCohortSet():
- Age
- Sex
- Prior history

Prevalencia
(puntual o de período)

Funciones principales

estimateIncidence():
- outcomeWashout
- repetitiveEvents

Incidencia → **plotIncidence()**

Denominador poblacional

generateDenominatorCohortSet():
- Age
- Sex
- Prior history

Prevalencia
(puntual o de período) → **plotPrevalence()**

estimatePointPrevalence():
- timePoint

estimatePeriodPrevalence()
- fullContribution

Índice

1. Conceptos
2. Interfaz y funciones principales
3. **Validación**
4. Elección de parámetros
5. Práctica

Validación

PDS Pharmacoepidemiology & Drug Safety
ispe Official Journal of the International Society for Pharmacoepidemiology

ORIGINAL ARTICLE | Open Access

IncidencePrevalence: An R package to calculate population-level incidence rates and prevalence using the OMOP common data model

Berta Raventós, Martí Català, Mike Du, Yuchen Guo, Adam Black, Ger Inberg, Xintong Li, Kim López-Güell, Danielle Newby, Maria de Ridder, Cesar Barboza, Talita Duarte-Salles ... See all authors

First published: 25 October 2023 | https://doi.org/10.1002/pds.5717

Berta Raventós and Martí Català should be considered as joint first-authors

Validación

Comparar los resultados del paquete con datos publicados:

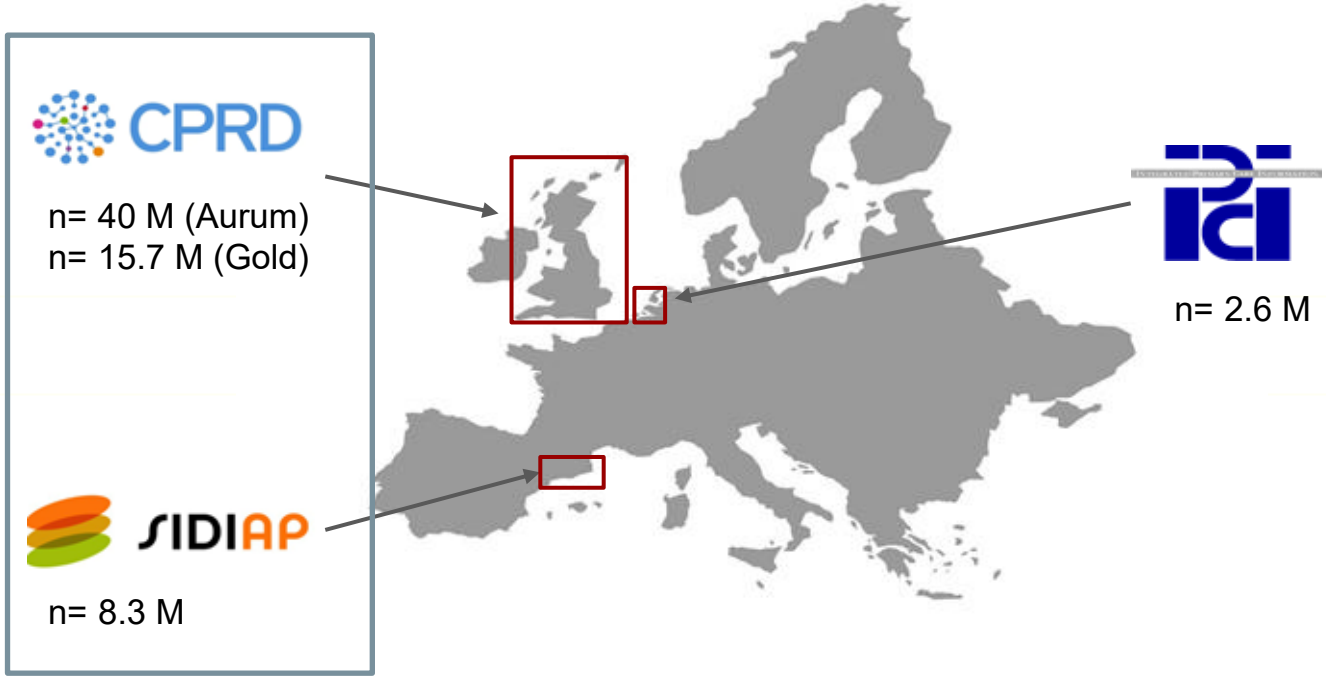

Validación

1. Incidencia de COVID-19 en Cataluña y Inglaterra:

Resultados obtenidos con IncidencePrevalence

Datos oficiales de COVID-19

(*) CPRD Aurum; datos restringidos a Inglaterra.

Validación

1. Incidencia de COVID-19 en Cataluña y Inglaterra:

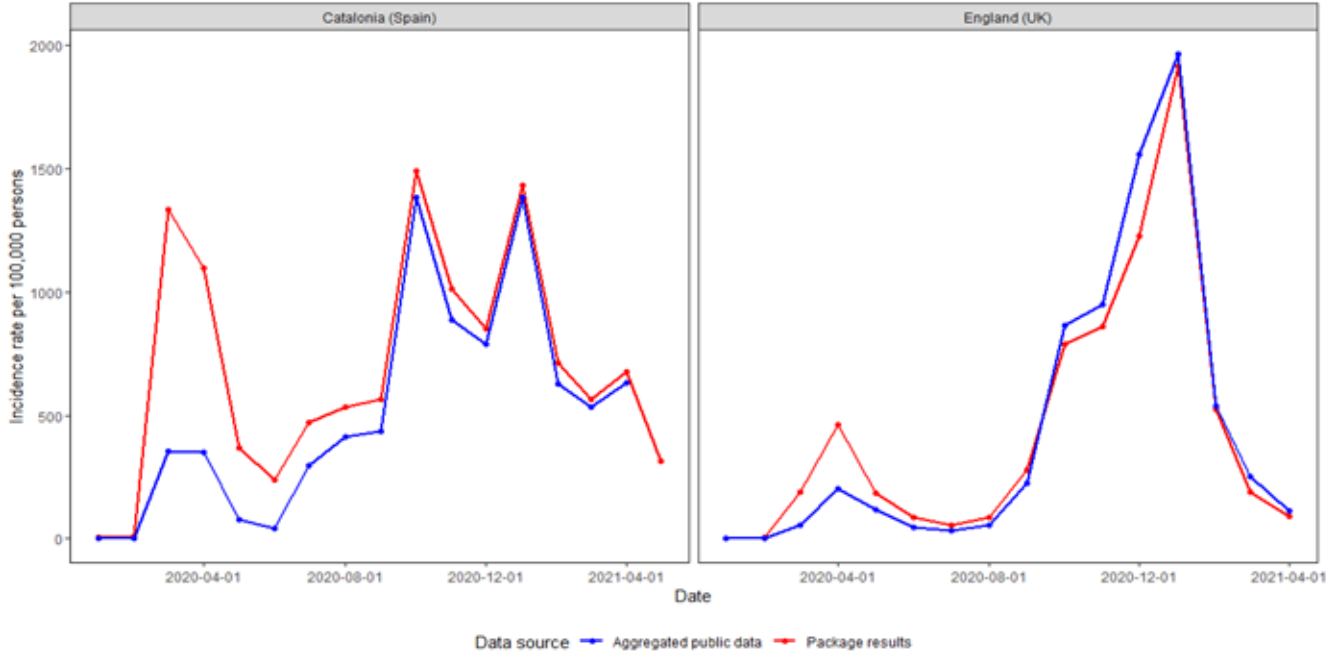

Validación

1. Incidencia de COVID-19 en Cataluña y Inglaterra

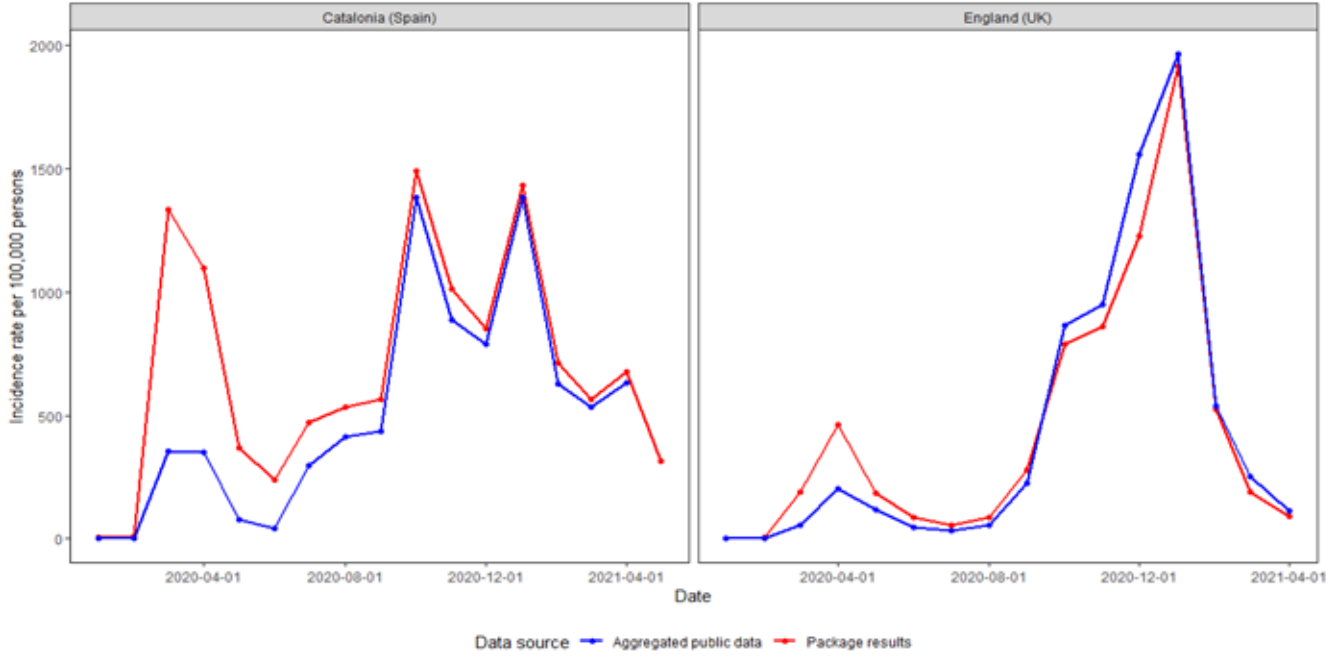

Diferencias en la definición de COVID-19

Validación

2. Incidencia de eventos adversos de especial interés (AESIs)

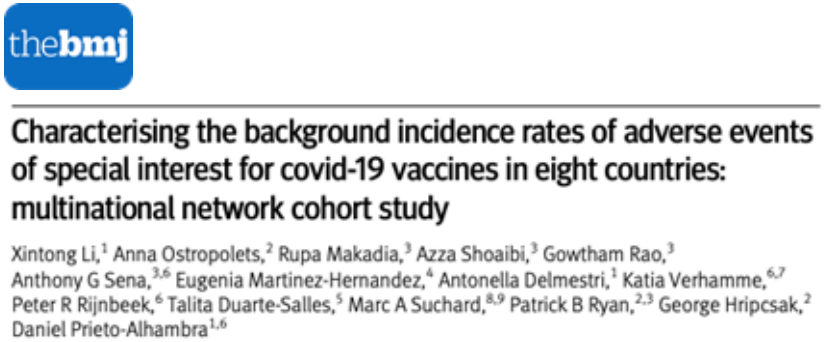

Resultados obtenidos con IncidencePrevalence

Resultados previamente públicados

(*) CPRD Gold

Validación

2. Incidencia de eventos adversos de especial interés (AESIs)

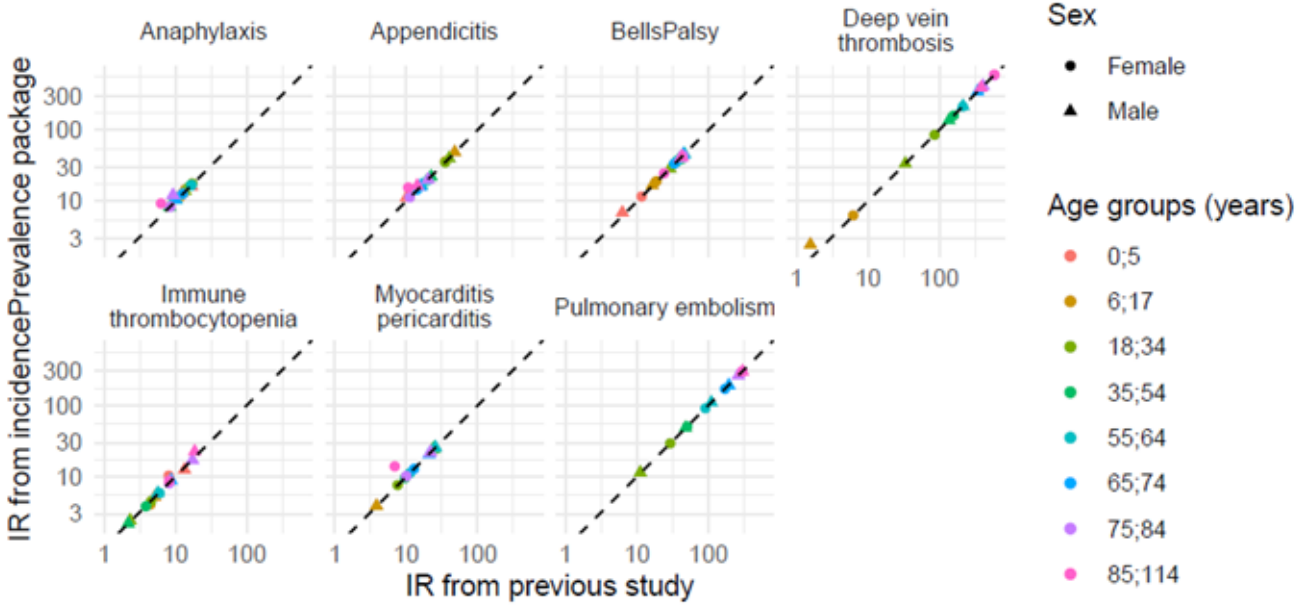

Benchmarking

- Denominador
  - 4 grupos de edad
  - 2 sexos
- Cohorte de *outcome* simulada (10% prev.)

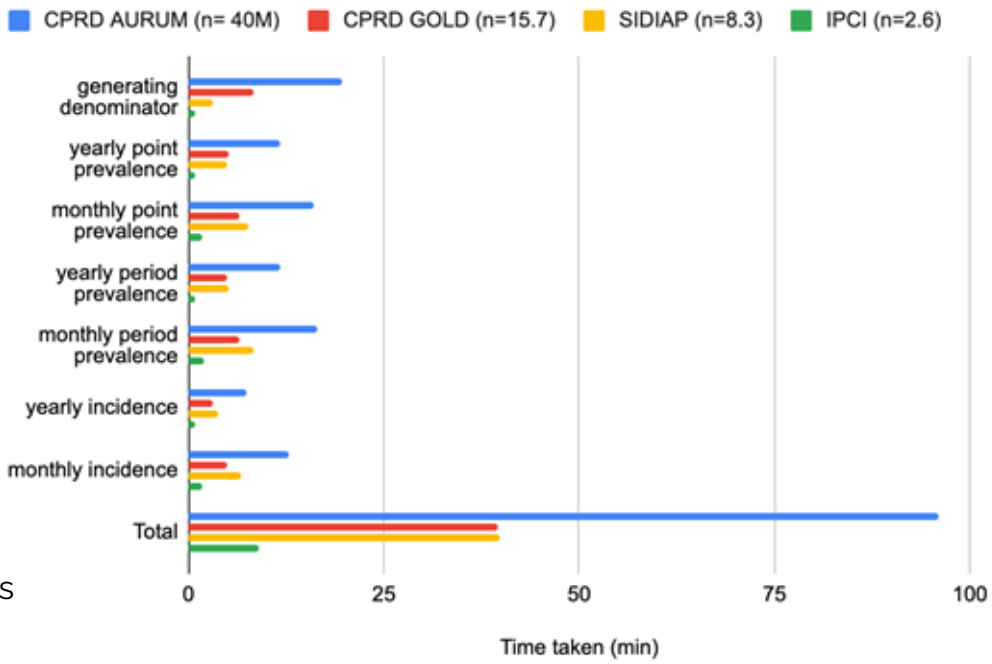

Tiempo de ejecución:
39.7 min (mediana)

El tiempo también depende de otros factores (e.g. tamaño de la base de datos)

Índice

1. Conceptos
2. Interfaz y funciones principales
3. Validación
4. **Elección de parámetros**

Elección de parámetros

Flexibilidad del páquete VS. responsabilidad parámetros escogidos

Elección de parámetros

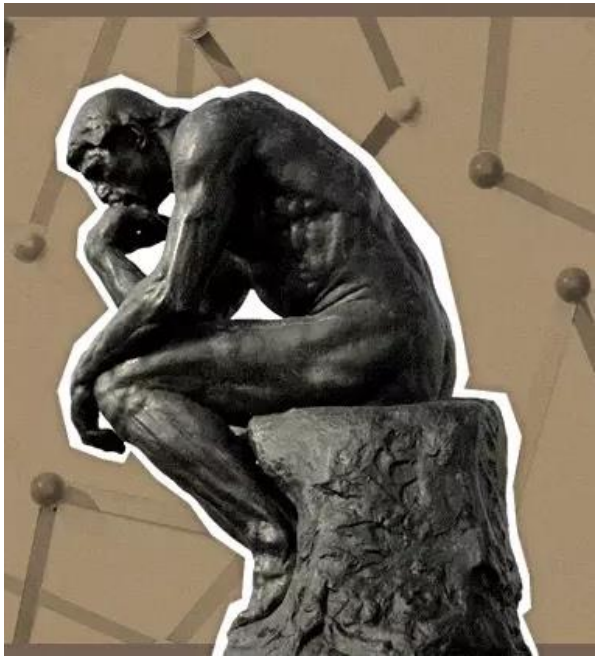

¿Hace falta historia previa?

¿Qué *washout* tengo que utilizar?

¿ Cuánto tiempo es prevalente un evento?

Elección de parámetros

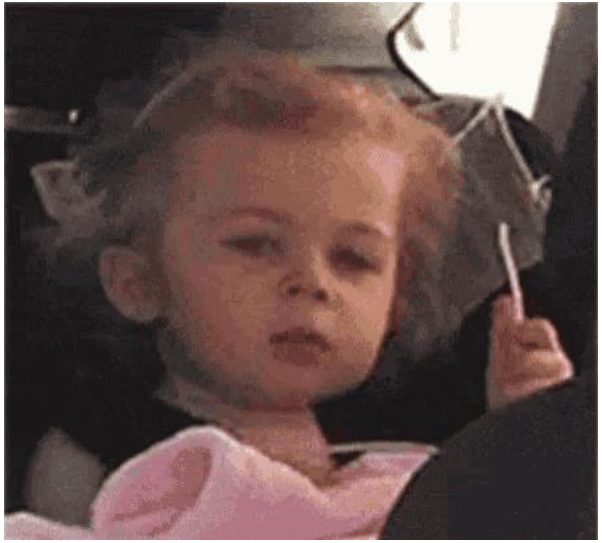

DEPENDE DE LA PREGUNTA DE INVESTIGACIÓN

¿Hace falta historia previa?

¿Qué *washout* tengo que utilizar?

¿ Cuánto tiempo es prevalente un evento?

Elección de parámetros

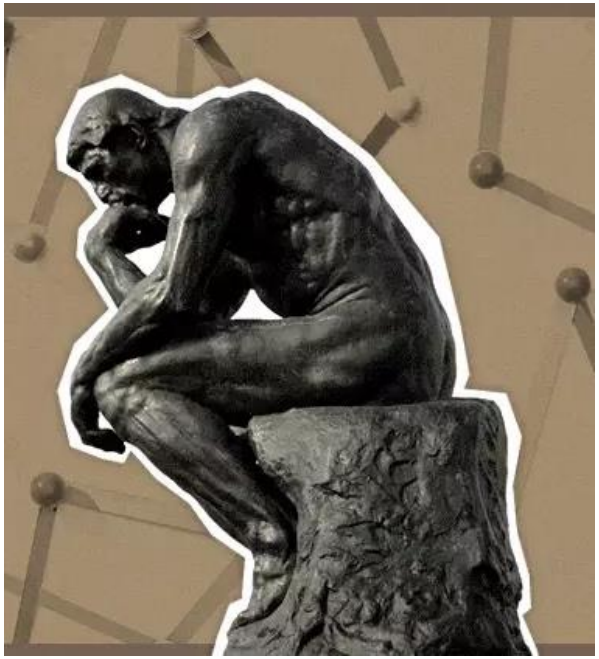

¿Hace falta historia previa?

¿Qué *washout* tengo que utilizar?

¿Cuánto tiempo es prevalente un evento?

Tiempo en observación

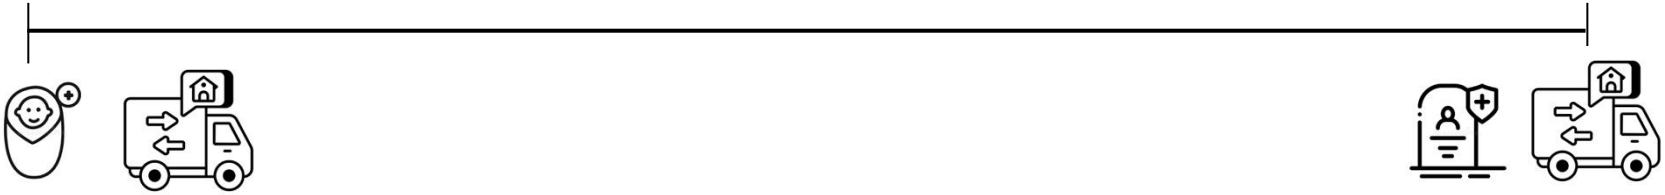

Tiempo en observación

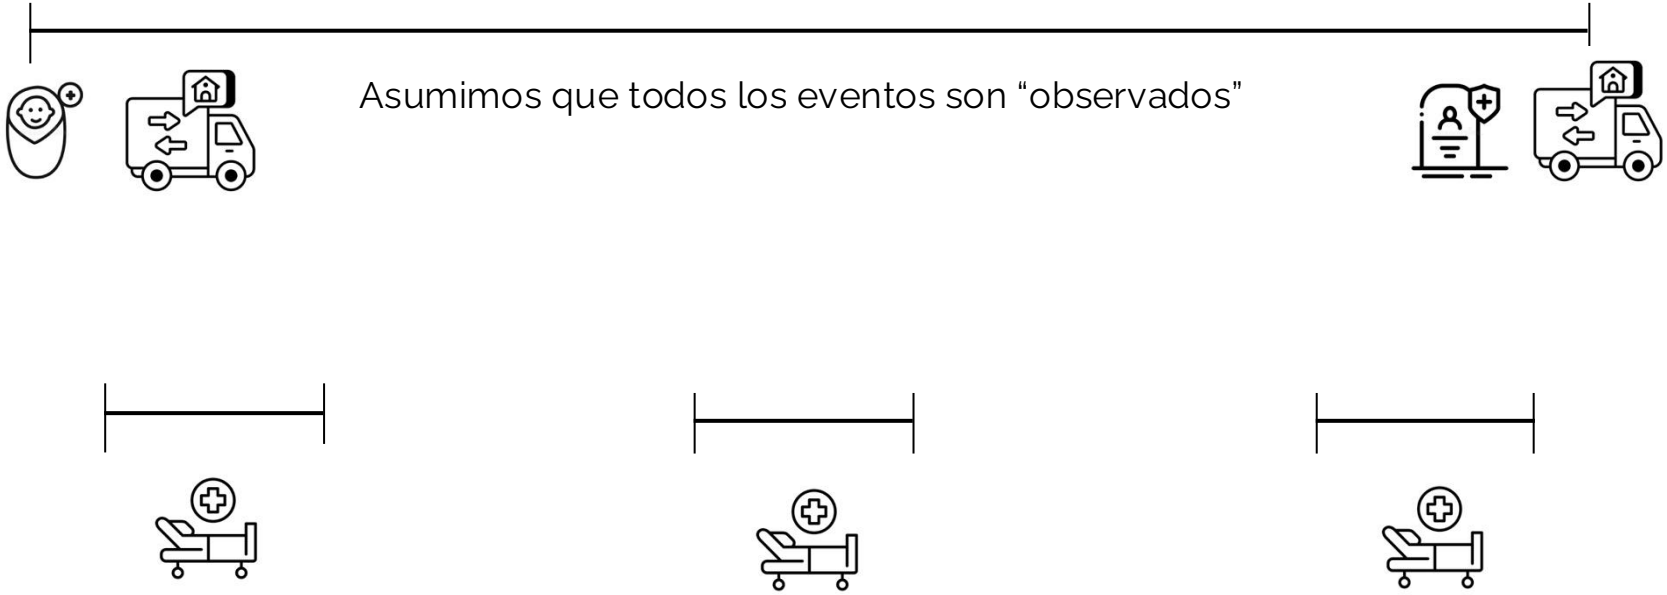

Tiempo en observación

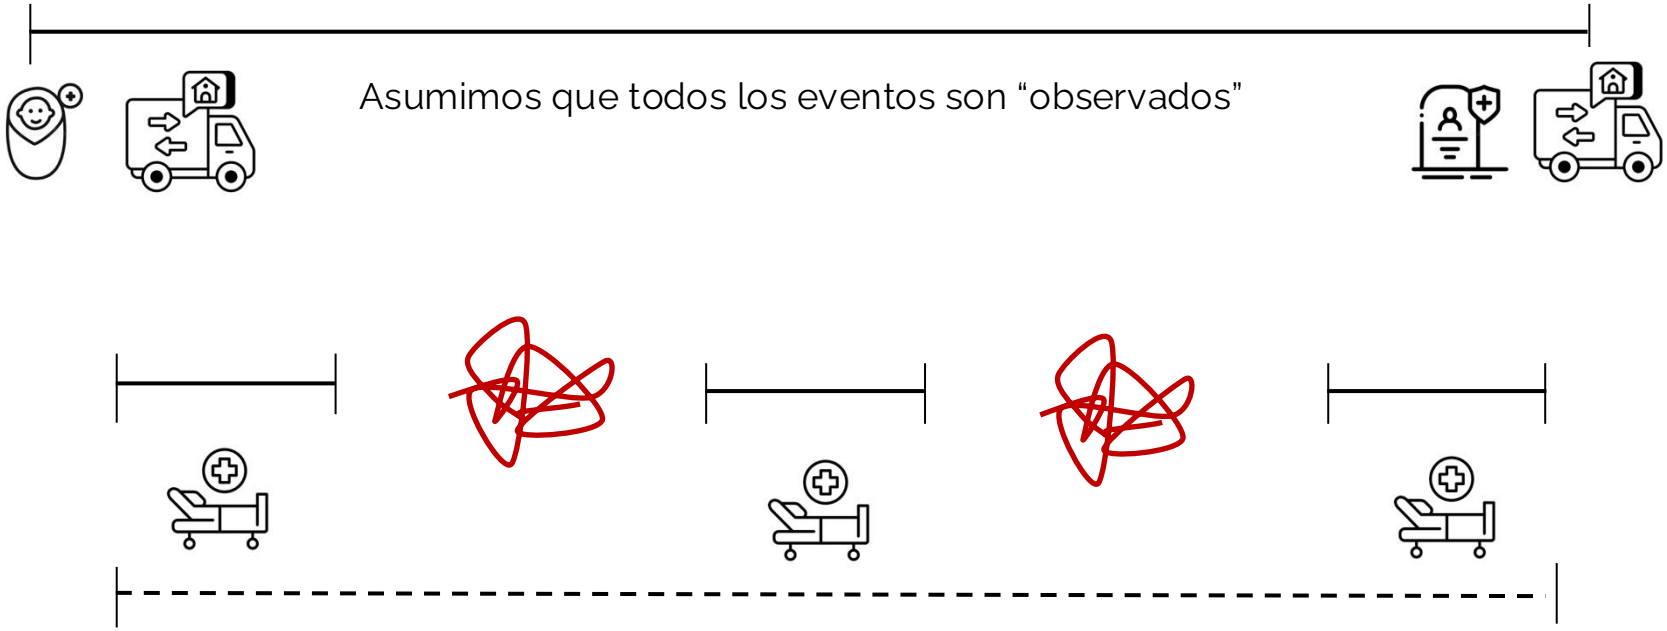

Tiempo en observación

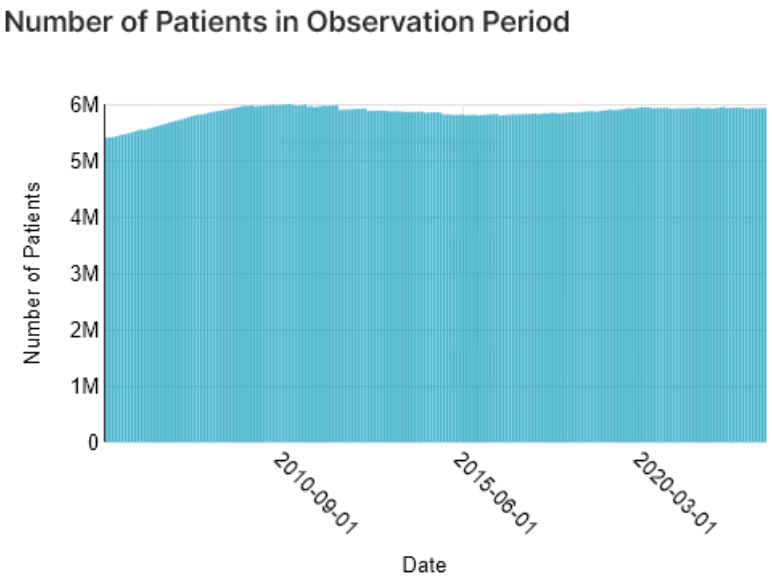

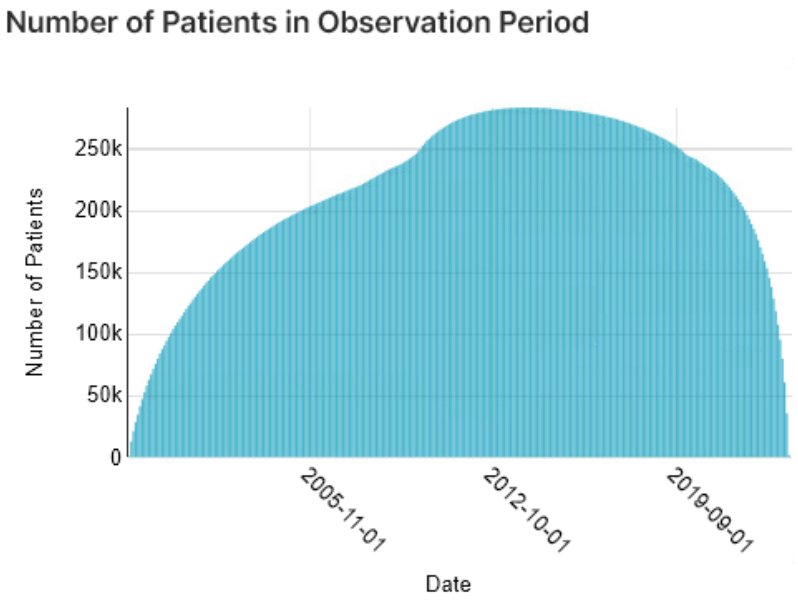

Tiempo en observación

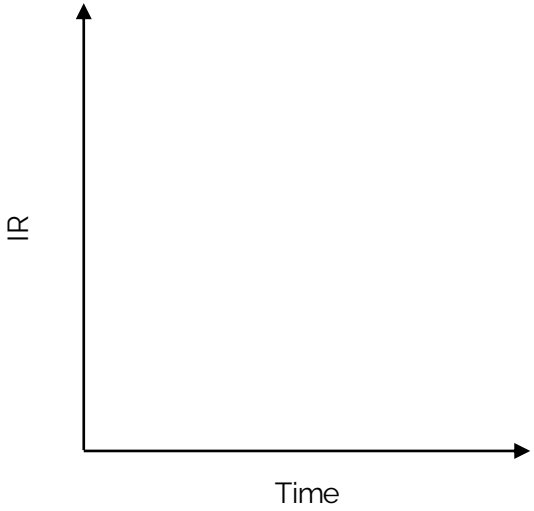

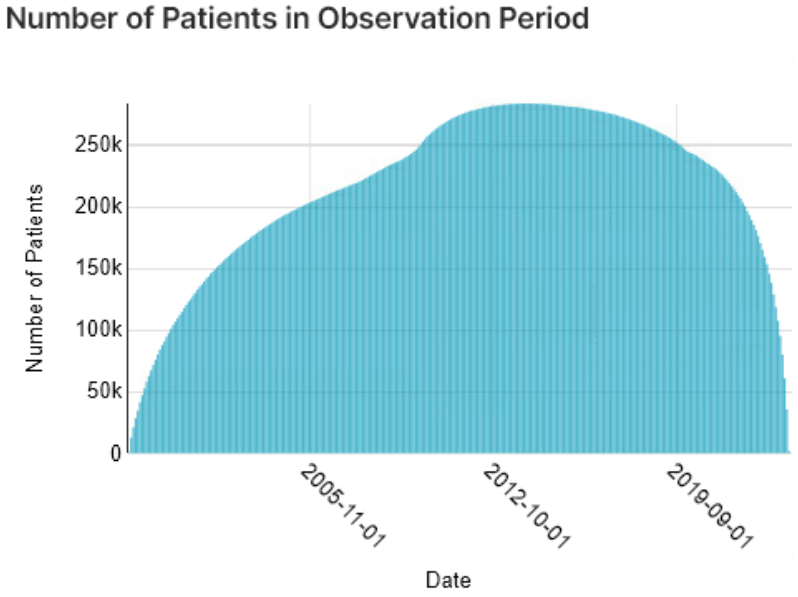

Tiempo en observación

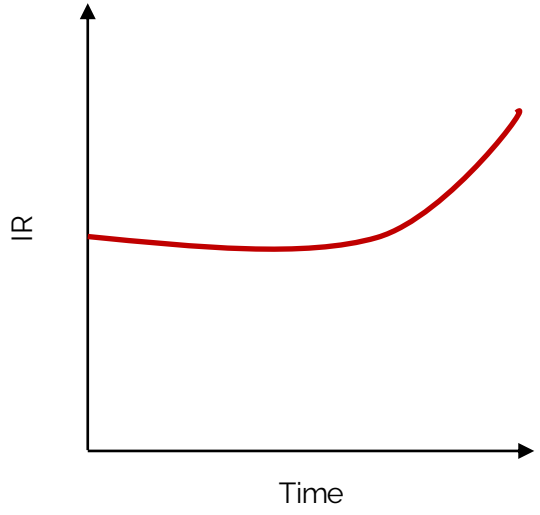

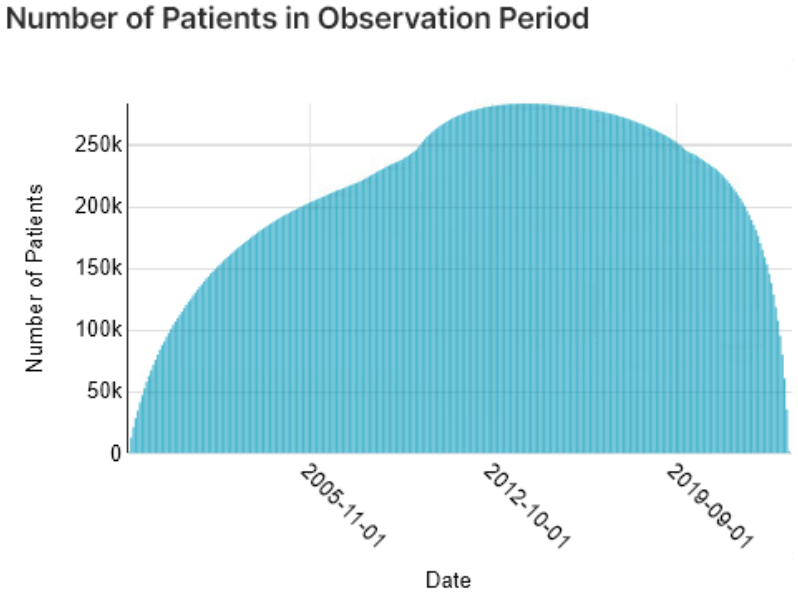

Elección de parámetros

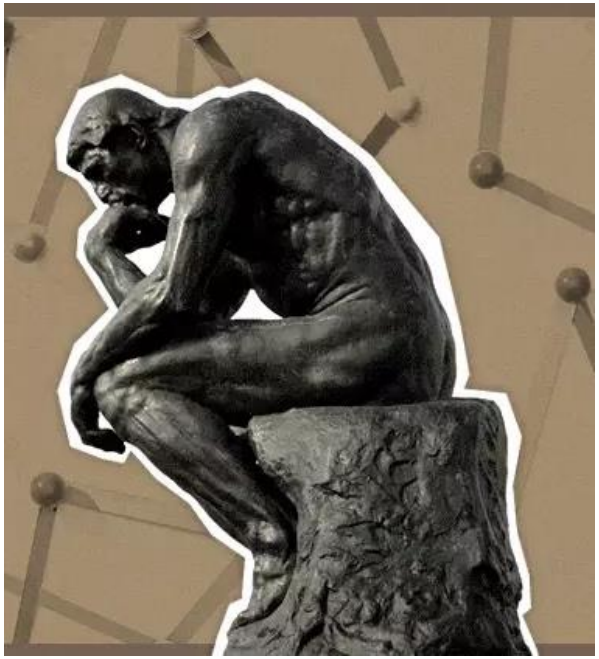

¿Hace falta historia previa?

¿Qué *washout* tengo que utilizar?

¿Cuánto tiempo es prevalente un evento?

Washout

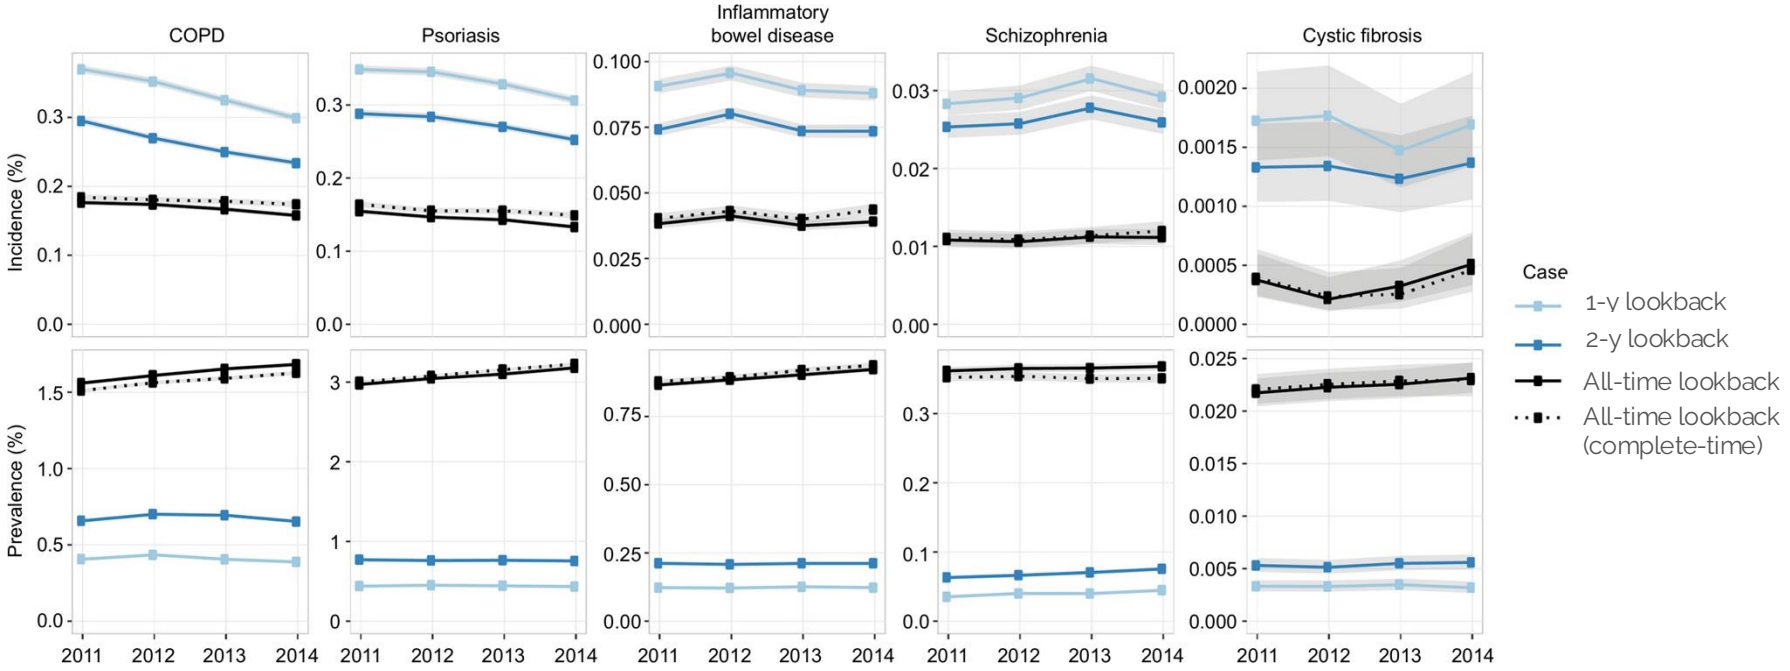

Períodos de *washout* más largos generan más posibilidades de identificar casos prevalentes, con menos casos que se clasifican como incidentes.

Source: Rassen JA, Bartels DB, Schneeweiss S, Patrick AR, Murk W. Measuring prevalence and incidence of chronic conditions in claims and electronic health record databases. Clin Epidemiol. 2018;11:1-15. Published 2018 Dec 17. doi:10.2147/CLEP.S181242

Elección de parámetros

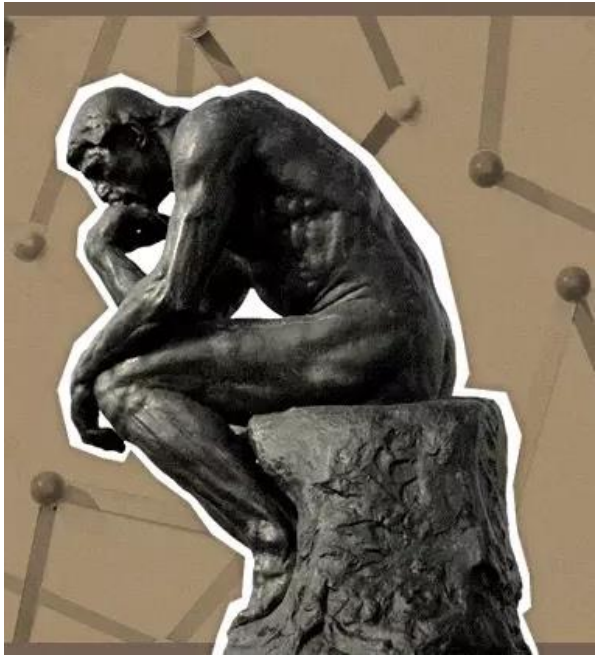

¿Hace falta historia previa?

¿Qué *washout* tengo que utilizar?

¿Cuánto tiempo es prevalente un evento?

Duración del evento de interés

¿Cuánto dura un diagnóstico en datos del mundo real?

Duración del evento de interés

¿Cuánto dura un diagnóstico en datos del mundo real?

¿Cómo podemos definir la duración de enfermedades que no son crónicas?

Duración del evento de interés

¿Cuánto dura un diagnóstico en datos del mundo real?

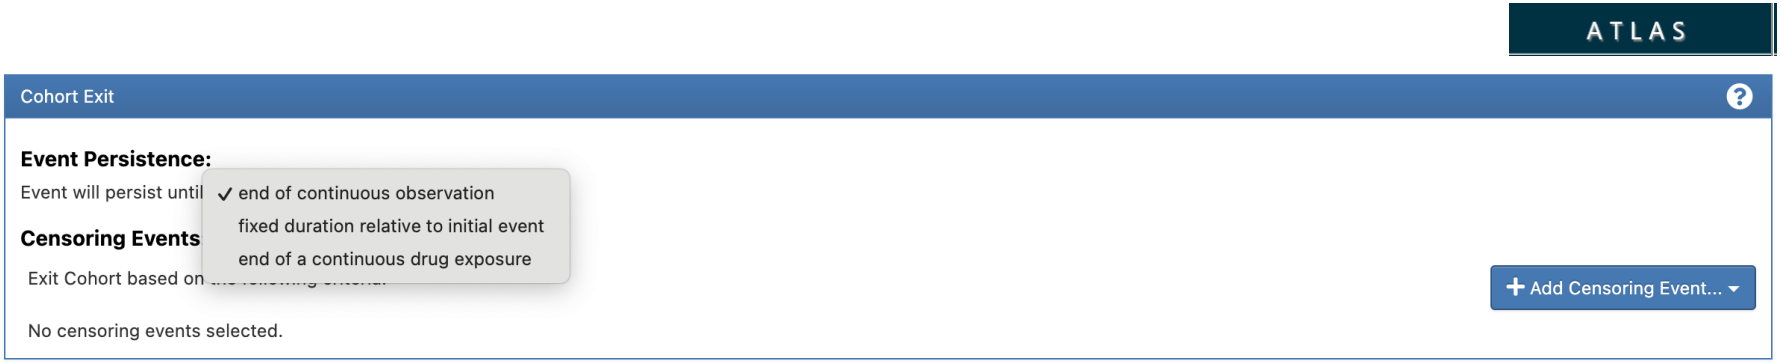

Elección de parámetros

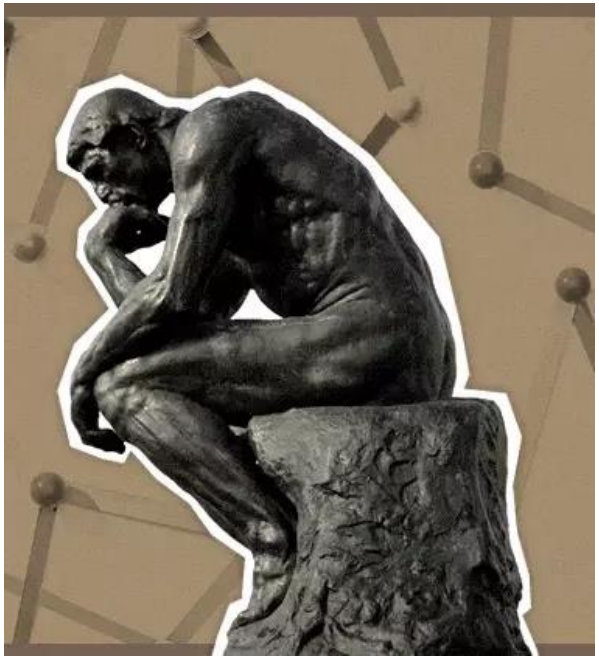

¿Hace falta historia previa?

¿Qué *washout* tengo que utilizar?

¿Cuánto tiempo es prevalente un evento?

Y muchas decisiones más..!

Índice

1. Conceptos
2. Interfaz y funciones principales
3. Validación
4. Elección de parámetros
5. **Práctica**

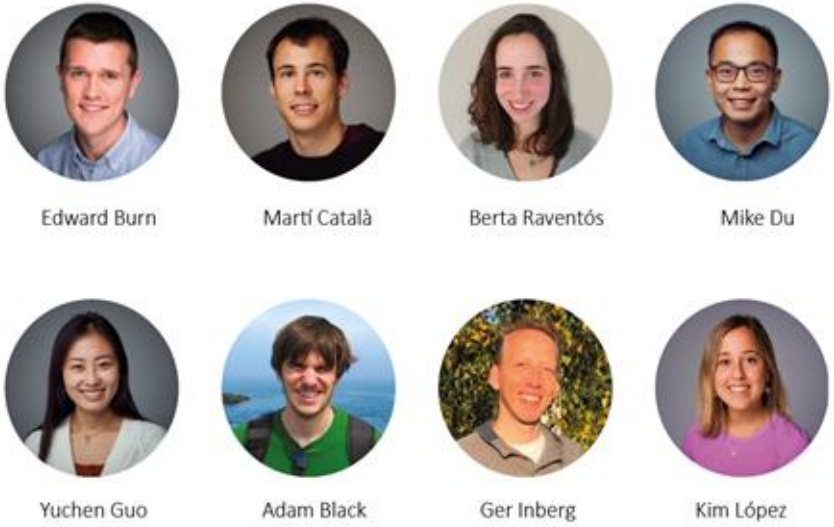

https://darwin-eu.github.io/IncidencePrevalence/

b.raventosiroca@erasmusmc.nl