Iniciación práctica al análisis de datos OMOP

Estudios en red usando datos OMOP: recomendaciones y buenas prácticas

Laura Granés

lgranes@idiapjgol.org

Marzo 2026

Estudios en red

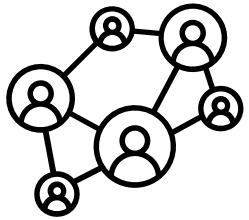

¿Por qué usarlos?

- Un estudio en una **sola base de datos** puede **no ser suficiente**, ya que los resultados pueden depender de **factores específicos del grupo de pacientes** (adherencia, genética, ambiente, estado de salud, etc.).
- Aumenta la **diversidad de fuentes y poblaciones**, evaluando si los resultados se **replican** en diferentes entornos.
- Identificar cómo los **factores "del mundo real"** afectan los hallazgos del estudio.

Un estudio se considera en red cuando el código analítico se ejecuta en distintas bases. Esto es posible gracias al mapeo a OMOP CDM.

Estudios en red: cambio de paradigma

Estudios en una base de datos

- Se diseña el estudio con una **base de datos específica en mente**.
- Se **seleccionan códigos** de conceptos basándose en lo conocido del propio conjunto de datos.
- **Riesgo de sesgo** en la definición de cohortes al limitarse a un entorno o región específica.

Estudios en red

- El estudio se diseña para ejecutarse en múltiples sitios globales, sin acceso directo a los datos de otras instituciones.
- Solo se comparten archivos de resultados (datos agregados), nunca datos individuales.
- Se requiere una **definición de cohortes exhaustiva** para cubrir la diversidad de entornos y bases de datos (CDM).

Estudios en red: Ejemplos

Long-Term Impact of the COVID-19 Pandemic on the Incidence of Depression Diagnoses and Antidepressant Prescribing: An International Network Cohort Study from Three European Countries

25 Pages • Posted: 6 Dec 2023

Berta Raventós
Fundació Institut Universitari per a la recerca a l'Atenció Primària de Salut Jordi Gol i Gurina (IDIAPJGol)

Carlen Reyes
Fundació Institut Universitari per a la recerca a l'Atenció Primària de Salut Jordi Gol i Gurina (IDIAPJGol)

More

Comparative risk of thrombosis with thrombocytopenia syndrome or thromboembolic events associated with different covid-19 vaccines: international network cohort study from five European countries and the US

BMJ 2022 ; 379 doi: https://doi.org/10.1136/bmj-2022-071594 (Published 26 October 2022)
Cite this as: *BMJ* 2022;379:e071594

Article | Open access | Published: 06 October 2020

Deep phenotyping of 34,128 adult patients hospitalised with COVID-19 in an international network study

Edward Burn, Seng Chan You, Anthony G. Sena, Kristin Kostka, Hamed Abedtash, Maria Tereza F. Abrahão, Amanda Alberga, Heba Alghoul, Osaid Alser, Thamir M. Alshammari, Maria Aragon, Carlos Areia, Juan M. Banda, Jaehyeong Cho, Aedin C. Culhane, Alexander Davydov, Frank J. DeFalco, Talita Duarte-Salles, Scott DuVall, Thomas Falconer, Sergio Fernandez-Bertolin, Weihua Gao, Asieh Golozar, Jill Hardin, ... Patrick Ryan + Show authors

Characterising the background incidence rates of adverse events of special interest for covid-19 vaccines in eight countries: multinational network cohort study

BMJ 2021 ; 373 doi: https://doi.org/10.1136/bmj.n1435 (Published 14 June 2021)
Cite this as: *BMJ* 2021;373:n1435

The burden of post-acute COVID-19 symptoms in a multinational network cohort analysis

Kristin Kostka, Elena Roel, Nhung T. H. Trinh, Núria Mercadé-Besora, Antonella Delmestri, Lourdes Mateu, Roger Paredes, Talita Duarte-Salles, Daniel Prieto-Alhambra, Martí Català & Annika M. Jödicke

Venous or arterial thrombosis and deaths among COVID-19 cases: a European network cohort study

Edward Burn, DPhil • Talita Duarte-Salles, PhD • Sergio Fernandez-Bertolin, MSc • Carlen Reyes, PhD • Kristin Kostka, MPH • Antonella Delmestri, PhD • et al. Show all authors

Estudios en red: ¿Cómo funciona?

Colaboración entre investigadores para responder a una pregunta de investigación.

Los *data partners* colaboran con datos y conocimiento en el estudio.

Estudios en red: Pasos a seguir

1. Definir le pregunta de investigación
2. Protocolo
3. Revisar la disponibilidad y la calidad de los datos
4. Definir la población de estudio
5. Factibilidad y Diagnóstico
6. Finalización protocolo
7. Ejecutar estudio
8. Interpretar resultados y diseminar

Estudios en red: Pasos a seguir

1. Definir le pregunta de investigación
2. **Protocolo**
3. Revisar la disponibilidad y la calidad de los datos
4. Definir la población de estudio
5. Factibilidad y Diagnóstico
6. Finalización protocolo
7. Ejecutar estudio
8. Interpretar resultados y diseminar

Cada *data partner* debe pasar las regulaciones específicas (comités científicos, éticos...)

Estudios en red: Pasos a seguir

1. Definir le pregunta de investigación
2. Protocolo
3. **Revisar la disponibilidad y la calidad de los datos**
4. Definir la población de estudio
5. Factibilidad y Diagnóstico
6. Finalización protocolo
7. Ejecutar estudio
8. Interpretar resultados y diseminar

EHDEN

EHDEN – portal: https://www.ehden.eu/

EHDEN

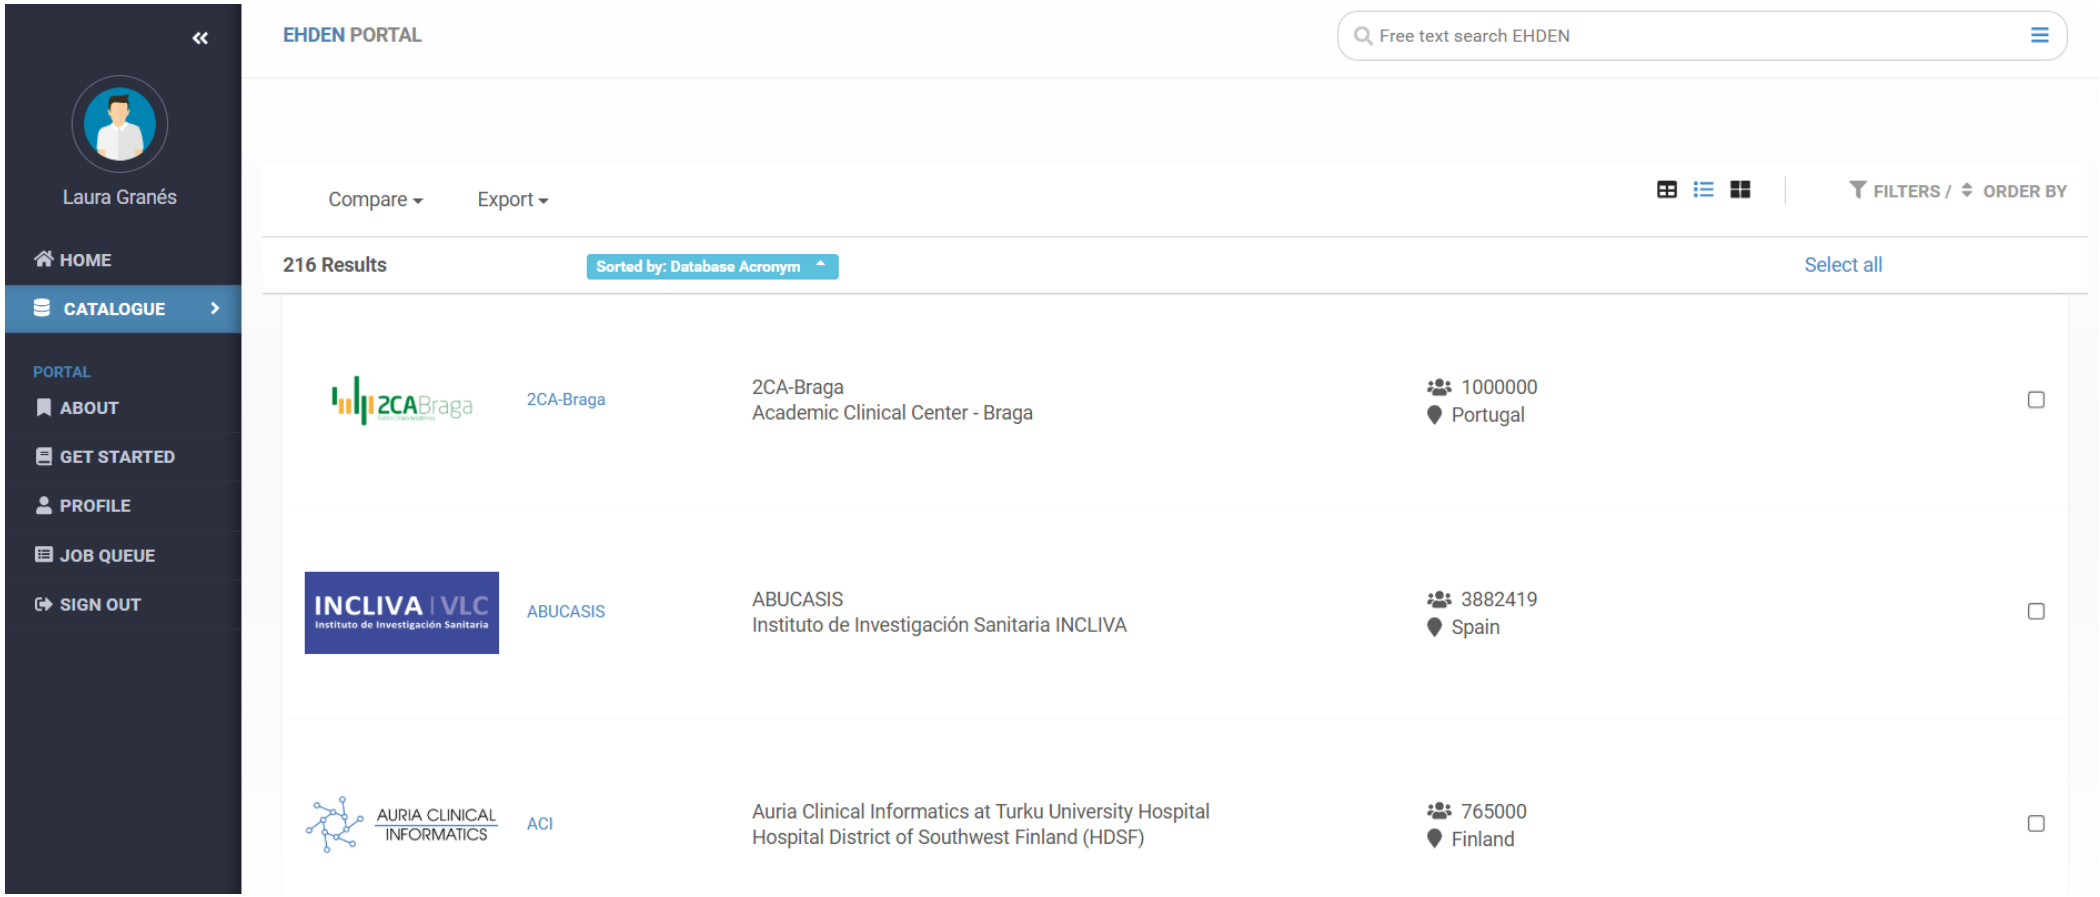
EHDEN PORTAL
Free text search EHDEN
Laura Granés
HOME
CATALOGUE
PORTAL
ABOUT
GET STARTED
PROFILE
JOB QUEUE
SIGN OUT
Compare
Export
FILTERS / ORDER BY
216 Results
Sorted by: Database Acronym
Select all
2CA-Braga
2CA-Braga
Academic Clinical Center - Braga
1000000
Portugal
ABUCASIS
ABUCASIS
Instituto de Investigación Sanitaria INCLIVA
3882419
Spain
ACI
Auria Clinical Informatics at Turku University Hospital
Hospital District of Southwest Finland (HDSF)
765000
Finland

EHDEN

Database-Level Dashboard

Demographics | Data Domains | Data Provenance | Observation Period | Visit | Concept Browser | Meta Data

Number of Patients

8.89M

Gender

gender	number of records
MALE	4.45M
FEMALE	4.45M

Gender

Age at first observation

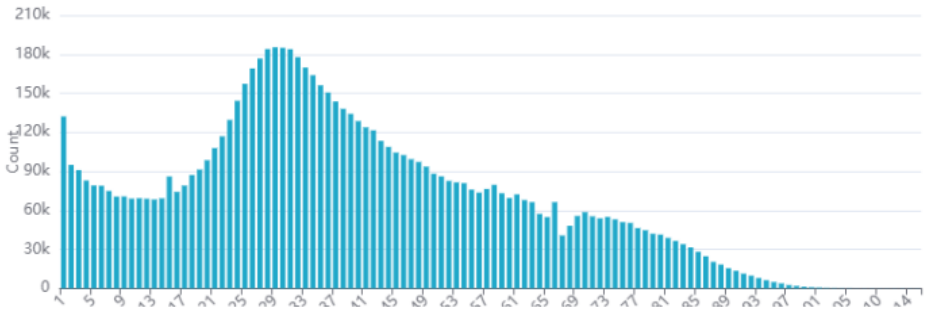

Distribution of age at first observation period

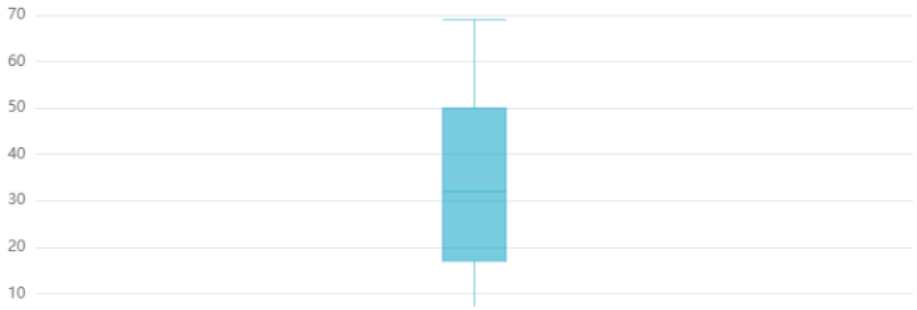

EHDEN

Database-Level Dashboard

Demographics | Data Domains | Data Provenance | Observation Period | Visit | Concept Browser | Meta Data

The concepts browser allows you to search for concepts by name or concept_id in all the data sources you select. No exact number of patients or occurrences are provided but they are rounded up to the nearest multiple of 100. Note that the number of patients and occurrences are for that concept only and does not include the children of that code.

By clicking on the concept_id you can view additional information about the concept in Athena

Concept Browser

Show 10 entries per page

Search body mass

concept_id	concept_name	domain_id	drc	rc
3038553	Body mass index (BMI) [Ratio]	Measurement	61098400	61098400
4060705	Body mass index 25-29 - overweight	Observation	100	100
4060985	Body mass index 30+ - obesity	Observation	200	200
4135421	Body mass index 20-24 - normal	Observation	100	100
4147565	Body mass index less than 20	Observation	300	300
4256640	Body mass index 40+ - severely obese	Observation	100	100

Estudios en red: Pasos a seguir

1. Definir le pregunta de investigación
2. Protocolo
3. Revisar la disponibilidad y la calidad de los datos
4. **Definir la población de estudio**
5. **Factibilidad y Diagnóstico**
6. Finalización protocolo
7. Ejecutar estudio
8. Interpretar resultados y diseminar

Estudios en red: *Phenotyping*

<u>Definir *phenotypes*</u>: Los investigadores principales hacen una **primera versión** que compartirán con los *data partners* para validarla en cada base de datos.

<u>Ejecutar validación</u>: Se comparte un repositorio con las definiciones de las cohortes y el código necesario (e.g. PhenotypeR) para **estudiar y validar cada una de las definiciones**. Cada *data partner* ejecuta el código y **revisa internamente** los resultados.

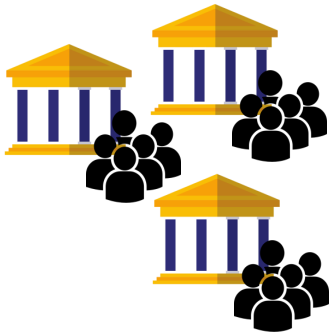

<u>Validación *phenotypes*</u>: Los *data partners* comparten los resultados con los investigadores principales. ***Data partners* y IP trabajan juntos para mejorar las definiciones**.

Proceso iterativo *(2-3 reruns)*

Estudios en red: Pasos a seguir

1. Definir le pregunta de investigación
2. Protocolo
3. Revisar la disponibilidad y la calidad de los datos
4. Definir la población de estudio
5. Factibilidad y Diagnóstico
6. Finalización protocolo
7. **Ejecutar estudio**
8. **Interpretar resultados y diseminar**

Estudios en red: Ejecución estudio

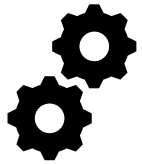

<u>Crear código analítico</u>: Los **investigadores principales desarrollan el código** que va a ser compartido con los *data scientist* de los centros colaboradores.

<u>Lanzar código</u>: Cada ***data partner* ejecuta** el código de estudio **de forma local** en su base de datos, y **revisa** los resultados de forma interna.

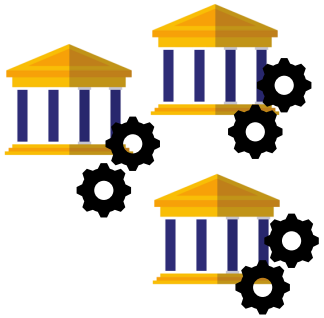

<u>Revisión resultados</u>: Los *data partners* comparten los resultados con los investigadores principales.

Pueden **surgir errores en el código** (e.g. distintas distribuciones de SQL), se pueden obtener resultados inesperados (e.g. diferencias en el mapeo).

Proceso iterativo *(2-3 reruns)*

Estudios en red: Revisión de resultados

- Shiny app

For each cohort in each database comparing vaccinated with unvaccinated people, covariate balance was calculated before and after propensity score weighting, with adequate balance achieved for all covariates after weighting, except for GP practice in CPRD AURUM and CPRD GOLD (for cohorts two and three only; results are accessible in the interactive web application). Propensity scores and overlap weight distributions for the primary outcome are included in the appendix (pp 132–133). Baseline characteristics for cohorts one to four are shown in table 1 for CPRD AURUM, and in the appendix for CPRD GOLD, SIDIAP, and CORIVA (pp 16–17, 26–29, 38–41, and 48–51), with all tables showing comparability of study participants when vaccinated and unvaccinated groups were compared after weighting. Negative control outcome analyses suggested some residual confounding after weighting; therefore, in the subsequent sections we report empirically calibrated estimates and uncalibrated estimates were reported only in the web application.

Menu

- Databases
- Cohort details
- Propensity scores
- Negative control outcomes
- Estimates
- Kaplan-Meier plots
- Censor data

Details of the databases that participated in the study

Identifier 'cdm_name' is the one used in the multiple selection panels of the shiny

	cdm_name	cdm_source_name	cdm_version	cdm_holder	cdm_release_date	vocabulary_version	person_cnt	observation_period_cnt
1	CPRD AURUM	cdm_aurum_p21_000557	5.3	OMOP	2018-06-14	v5.0 29-AUG-22	10,592,564	10,592,564
2	CORIVA	CORIVA_covid_data_from_Feb_2023_NEW	5.3.1	UT		v5.0 19-NOV-21	438,433	438,433
3	CPRD GOLD	cdm_gold_202201	5.3	OMOP		v5.0 09-APR-22	16,958,587	16,958,587
4	SIDIAP	SIDIAP	5.3.1	SIDIAP	2022-11-14	v5.0 22-JUN-22	8,265,343	8,265,343

Showing 1 to 4 of 4 entries

Iniciación práctica al análisis de datos OMOP

Retos y buenas prácticas

25ANYS IDIAP JORDI GOL

Retos y buenas prácticas

R: ¿Cómo **compartir** el código analítico, jsons de cohortes, shiny app, etc. ?

BP: Utilizar un repositorio de **GitHub** (como el del curso)

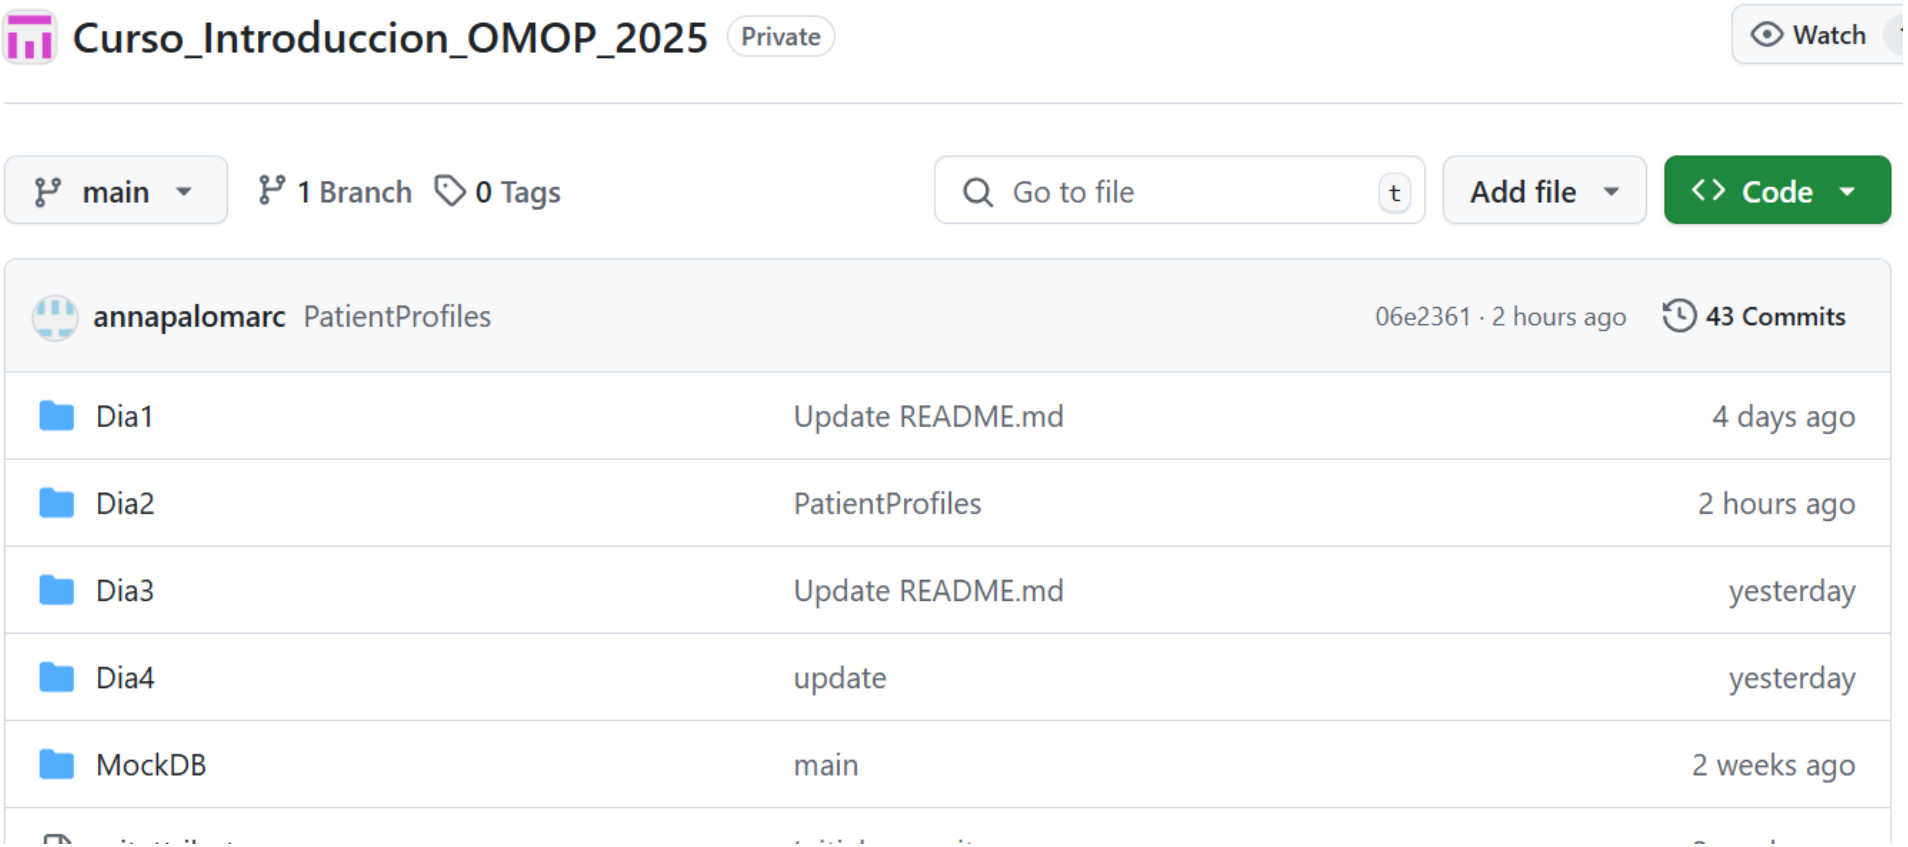

Retos y buenas prácticas

R: ¿Cómo **guiarse** dentro de un repo que te han compartido?

BP: **README** en el GitHub con las **instrucciones** para ejecutar el código.

README

Curs OMOP - Estudi COVID-19

Executing diagnostics

1. Download this entire repository (you can download as a zip folder using Code -> Download ZIP, or you can clone it using GitHub Desktop).
2. Open the folder "Diagnostics/CohortDiagnostics" and execute the script CodeToRun.R which will execute the diagnostics of the .json files in "cohorts".
3. When finished, copy the PreMerged.RData file to the subfolder "data" in CohortDiagnosticsShiny. Open the global.R script and execute the shiny.

Running the analysis

1. Download this entire repository (you can download as a zip folder using Code -> Download ZIP, or you can clone it using GitHub Desktop).
2. Open the folder StudyCode and the project StudyCode.Rproj in RStudio (when inside the project, you will see its name on the top-right of your RStudio session).
3. Open and work through the CodeToRun.R file which should be the only file that you need to interact with. Run the lines in the file, adding your database specific information and so on (see comments within the file for instructions). The last line of this file will run the study (source(here("RunStudy.R")).
4. After running you should then have folder with your results.
5. To visualise the results in the shiny, open the project 5_ShinyApp.RProj inside the folder 5_ShinyApp. Copy the .csv files in the folder "data", and then execute the app.R script to interact with the shiny.

Retos y buenas prácticas

R: ¿Cómo **trabajar con un código** que no has escrito tu?

BP: Tener un **proyecto de R** y un único script "**CodeToRun**" o similar que sea el único con el que se tenga que interactuar para ejecutar el código.

cohorts	11/12/2024 11:34	Carpeta de archivos	
concept_sets	11/12/2024 11:34	Carpeta de archivos	
2_study.Rproj	04/12/2024 11:25	Archivo RPROJ	1 KB
codeToRun.R	04/12/2024 11:25	Archivo R	2 KB
README.md	04/12/2024 11:25	Archivo MD	7 KB
renv.lock	04/12/2024 11:25	Archivo LOCK	19 KB
RunStudy.R	04/12/2024 11:25	Archivo R	5 KB

Retos y buenas prácticas

R: ¿Cómo trabajar con un código que no has escrito tu/Cómo crear código para otros?

BP: **CodeToRun** definir las variables de R específicas de cada *data partner*

```
# The name/ acronym for the database
dbName <- "..."   Nombre de la base de datos

# Database connection details
db <- dbConnect(
   RPostgres::Postgres(),
   dbname = server_dbi,
   port = port,
   host = host,
   user = user,
   password = password
)   Detalles de conexión a la base de datos

# The name of the schema that contains the OMOP CDM with patient-level data
cdmSchema <- "..."

# A prefix for all permanent tables in the database
writePrefix <- "..." Prefijo de conexión.

# The name of the schema where results tables will be created
writeSchema <- "..."

# minimum counts that can be displayed according to data governance
minCellCount <- 5 Numero de eventos mínimos para reportar resultados.
```

Retos y buenas prácticas

R: ¿Qué pasa con las diferentes actualizaciones y **versiones** de los **paquetes**?

BP: El paquete de R "**renv**" permite **reproducir el entorno** R del proyecto en el que se ha desarrollado el código.

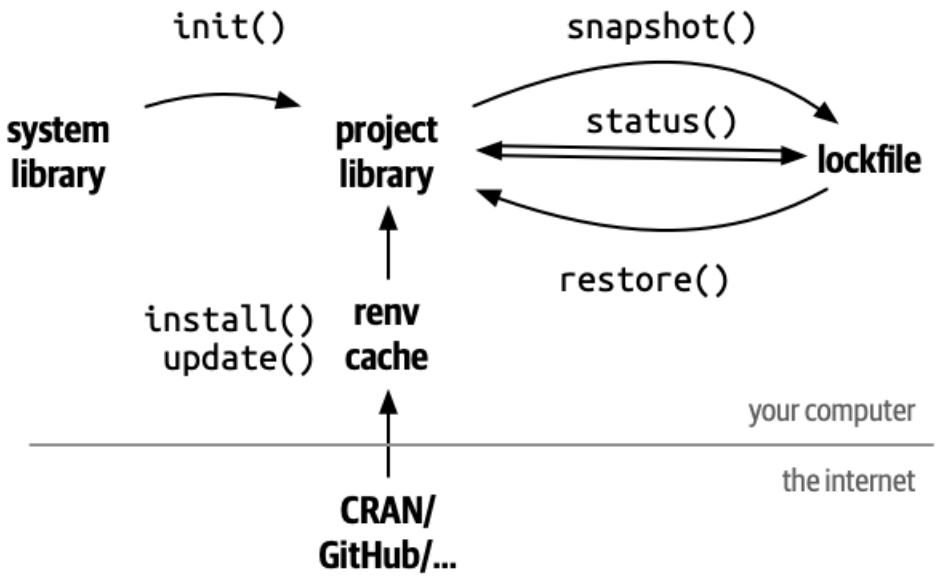

Retos y buenas prácticas

R: ¿Cómo **facilitar que otros entiendan tu código y lo puedan reutilizar**?

BP: Especificar el paquete que contiene cada función

```
omopgenerics::settings
CohortConstructor::conceptCohort
```

Retos y buenas prácticas

R: ¿Cómo detectar el **error** en un **código** que no has escrito/ejecutado tu?

BP: Implementar herramientas para **seguir el progreso de la ejecución código** (e.g. paquete **log4r**).

```
INFO  [2024-04-10 00:50:06] CREATE LOGGER
INFO  [2024-04-10 00:50:06] STEP 0 INITIAL SETTINGS ----
INFO  [2024-04-10 00:50:07] STEP 1 INSTANTIATE COHORTS ----
INFO  [2024-04-10 00:50:07]   - JSON cohorts
INFO  [2024-04-10 00:50:26]   - Denominator cohort
INFO  [2024-04-10 00:51:08] STEP 2 CALCULATE INCIDENCE ----
INFO  [2024-04-10 00:52:47] STEP 3 CHARACTERISATION ----
INFO  [2024-04-10 00:53:15] STEP 4 SURVIVAL ----
INFO  [2024-04-10 00:53:41] STEP 5 ZIP RESULTS ----
INFO  [2024-04-10 00:53:42]  -- DONE! --
```

Retos y buenas prácticas

R: ¿Qué pasa si…? Se detecta un **error** al final del código, se hacen **cambios** en una parte del código, **se para la ejecución** por algún imprevisto (corte de luz)

BP: Separar en partes **independientes distintos procesos del análisis**.

```
# Jobs to Run
executarInstanciarCohorts <- TRUE
executarCaracteritzacio   <- TRUE
executarIncidencia        <- TRUE
executarSupervivencia     <- TRUE
```

Retos y buenas prácticas

R: ¿Puedo **reaprovechar código** analítico de estudios similares?

BP: Código abierto.

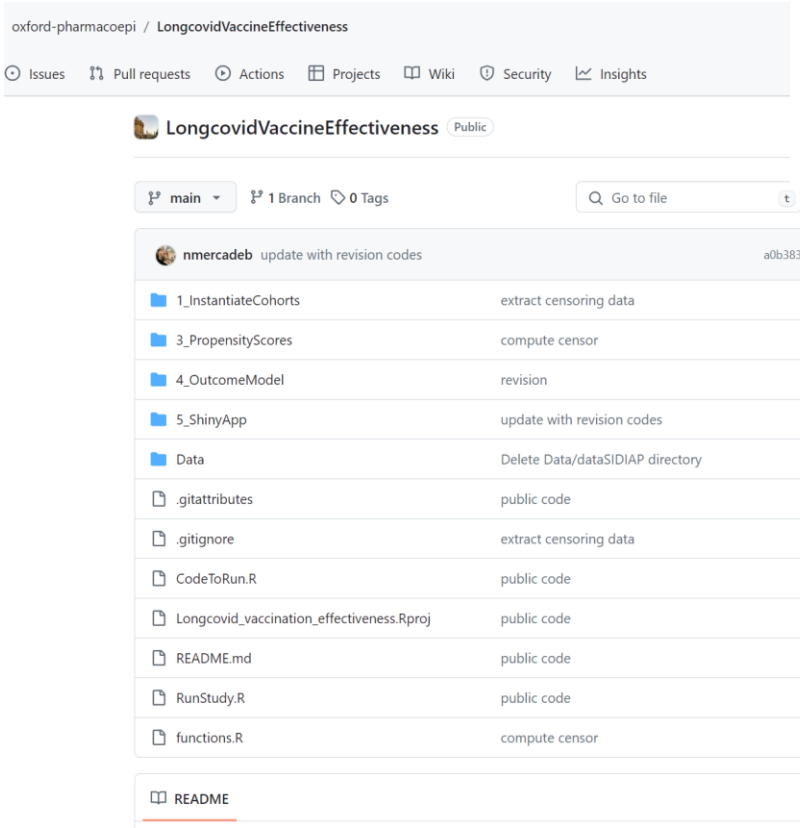

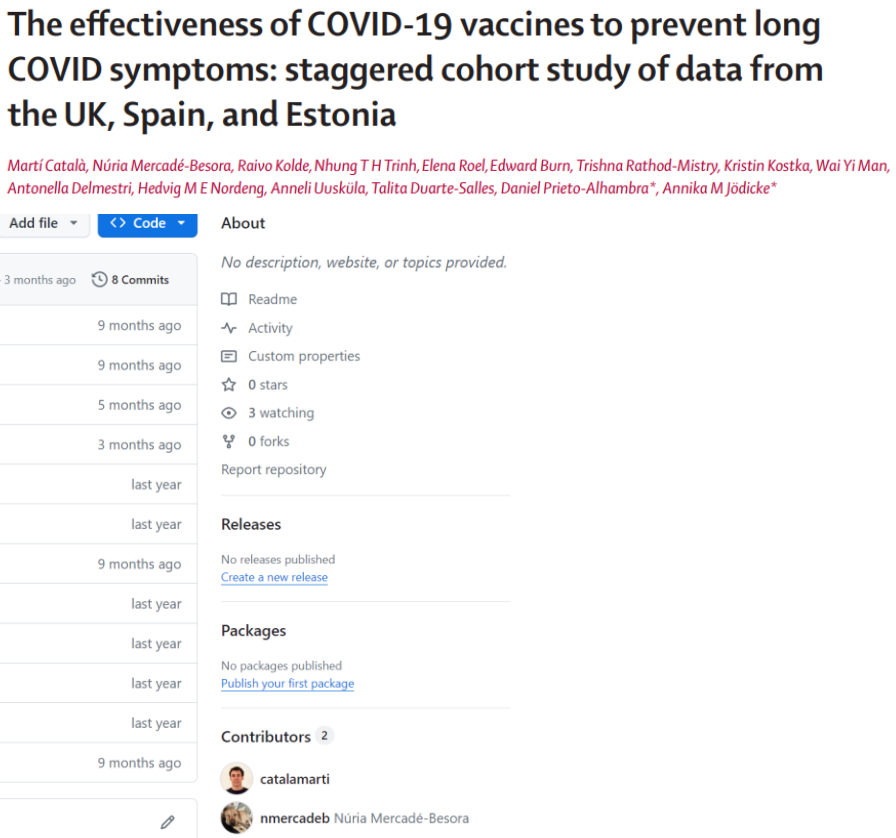

Retos y buenas prácticas

R: ¿Y si existen diferencias en el mapeo entre bases de datos?

BP: Es importante generar listas amplias de conceptos que puedan capturar problemas de salud en diversas bases de datos, evaluar las cohortes y **comunicarse** con los PI/data partners

Retos y buenas prácticas

R: ¿Qué pasa si vemos **resultados inesperados** en otra base de datos?

BP: Los *data partners* son quien mejor **conocen la base de datos** y sus **particularidades**, y son los que mejor pueden interpretar un resultado, que puede depender de cómo se diagnostica cierta enfermedad en su entorno, si el fármaco en estudio se prescribe o no, cuándo se ha introducido un fármaco/vacuna en el país, etc. Es importante la **comunicación**

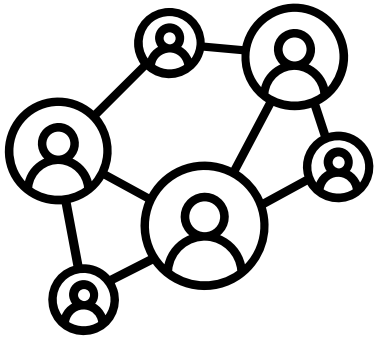

¡Muchas gracias por vuestra atención!